

#### 软件分析

# 数据流分析: 基础

熊英飞 北京大学

#### 示例: 符号分析



• 给定一个只包含整数变量和常量的程序,已知输入的符号,求输出的符号

#### 回顾:

## 表达式上的抽象和近似



输入x和y都是正数 求表达式x+1-1+y的符号 抽象符号 正 ={所有的正数} 零={0} 负= {所有的负数} 槑={所有的整数和NaN}

表达式	具体值范围	抽象值	抽象值范围
x	[1, +∞]	正	[1, +∞]
x+1	[2, +∞]	正	[1, +∞]
x+1-1	[1, +∞]	槑	$[-\infty, +\infty]$
У	[1, +∞]	正	[1, +∞]
x+1-1+y	[2, +∞]	槑	$[-\infty, +\infty]$

输入是集合时,表达式返回值也是集合。精确集合难以直接计算,所以用抽象值来近似。抽象值需要保证覆盖精确集合的范围。

### 抽象域的运算和正确性



- 引入γ表示抽象值对应的集合
  - γ(正) ={x∈ 整数 | *x* > 0}
- α将具体域的值映射到抽象域
  - $\alpha(1) = \mathbb{I}$
  - 需要满足:  $x \in \gamma(\alpha(x))$

$\oplus$	正	负	零	槑
正	正			
负	槑	负		
零	正	负	零	
槑	槑	槑	槑	槑

- · 运算操作+, -, ×,/分别定义抽象域上的版本⊕,⊖,,⊗,∅
  - 需要满足输入抽象域包含的任何具体值计算结果在输出抽象域中
  - 如:  $\forall x \in \gamma(\mathbb{P}) \land y \in \gamma(\mathbb{Z}), x + y \in \gamma(\mathbb{P} \oplus \mathbb{Z})$

#### 程序 vs 表达式



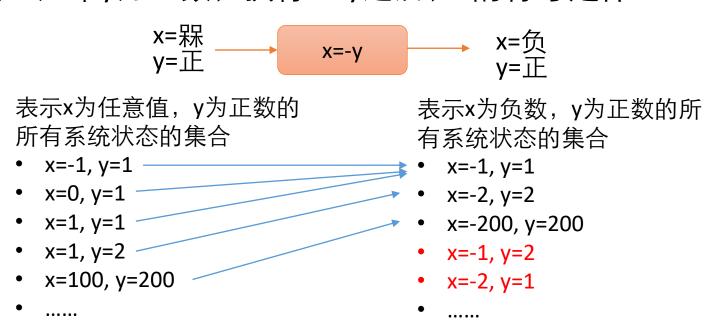
- •程序中多了如下概念,如何用抽象方法进行分析?
  - 语句
  - 顺序
  - 分支
  - 循环
- 处理这一系列程序中抽象概念的方法叫做数据流分析
  - 数据流分析将程序转换成控制流图,并在控制流图上 完成分析

暂时不考虑指针、数组、结构体、函数调用、动态内存分配等高级编程语言 成分,将在未来课程中处理

#### 从表达式到语句



- 抽象域表示系统状态中值的集合
  - 系统状态: 从变量名到值的映射
  - 抽象状态: 从变量名到抽象值的映射
- 例:如果y为正数,执行x=-y之后,x的符号是什么?

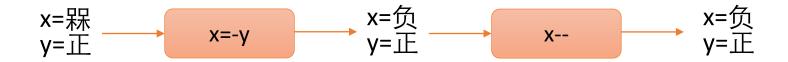


正确性:输入抽象值包含的任意具体状态的执行结果在输出抽象值中

#### 语句的顺序组合



- 依次执行语句即可
- 例:如果y为正数,执行x=-y;x--;之后,x的符号 是什么?



正确性:输入抽象值包含的任意具体状态的执行结果在输出抽象值中

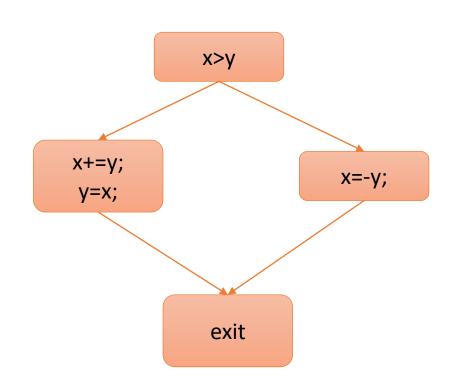
#### 分支



```
• 例
```

```
if (x>y) {
  x+=y;
  y = x; }
else {
  x = -y;
}
```

- 输入:
  - x=<u>I</u>
  - y=正
- 求输出的符号



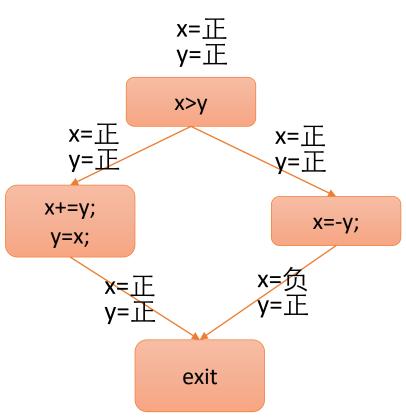
输入抽象值对应具体状态左右路径都有可能走

#### 分支



```
• 例
if (x>y) {
    x+=y;
    y = x; }
else {
    x = -y;
}
```

- 输入:
  - x=<u>I</u>
  - y=正
- 求输出的符号

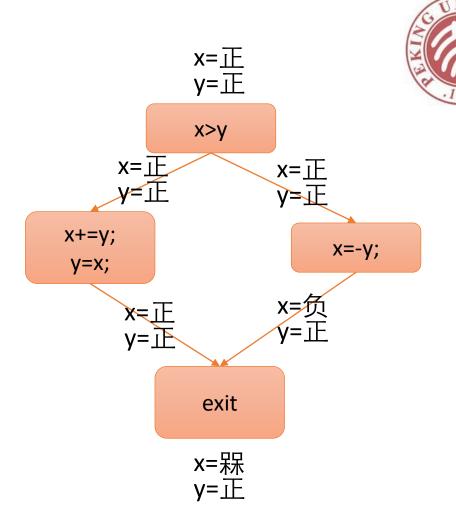


针对两条路径分别计算

#### 分支

```
• 例
if (x>y) {
    x+=y;
    y = x; }
else {
    x = -y;
}
```

- 输入:
  - x=正
  - y=正
- 求输出的符号

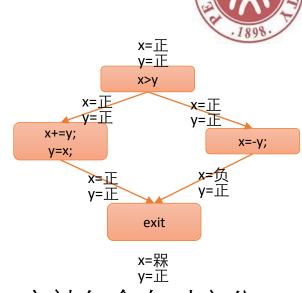


#### 定义合并操作:

$$\sqcup (v_1, v_2) = \begin{cases} v_1 & \text{如果} v_1 = v_2 \\ \mathbf{R} & \text{其他情况} \end{cases}$$

#### 分支分析正确性

- 输入抽象值包含的任意 具体状态的执行结束状态在输出 抽象值中
- 证明:
- 1. 对任意具体状态,只会走单一路径
- 2. 分叉时,抽象值不变,所以该具体状态一定被包含在对应分 支的路径上
- 3. 任一分支一定保证执行结束状态在输出抽象值中





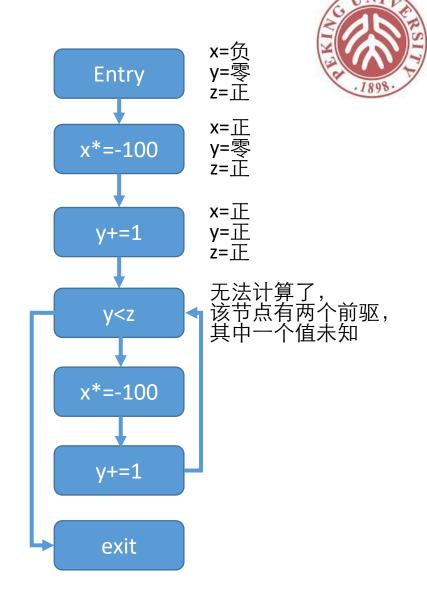
```
x*=-100;
y+=1;
while(y < z) {
    x *= -100;
    y += 1;
}</pre>
```

输入: x为负, y为零, z为正

输出: x为槑, y为正, z为正

#### 循环——思路

- 循环在控制流图上也是表现为分叉和合并两种
- 采用分支同样的方式处理

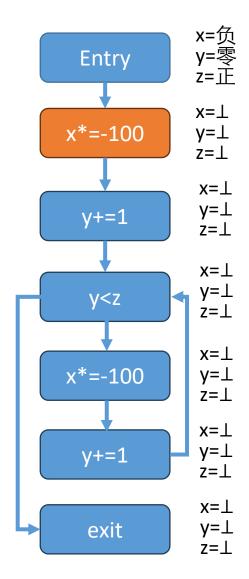


#### 循环——解决方案



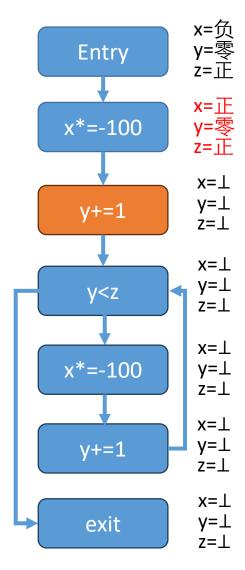
- •引入抽象值」
  - $\gamma(\bot) = \emptyset$
- □操作扩展到⊥: x □⊥= x
- 初始节点上的抽象值都为工,表示没有对应具体 状态
- 在分析过程中逐步扩大抽象值,加入可能的具体 状态
- 如果抽象值不再增大,则分析结束

- 一开始
  - 输入节点为输入的抽象 值
  - 其他节点的抽象值都为空
- 把输入节点的后继都加入待更新集合



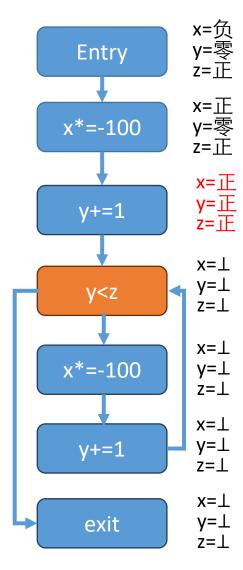


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合



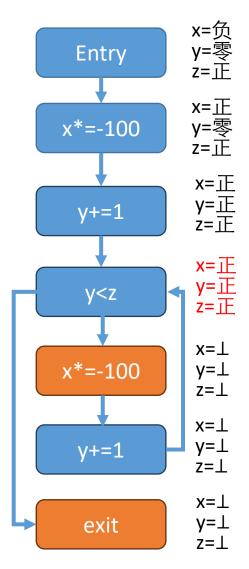


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合



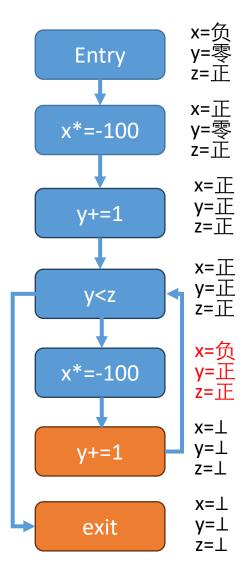


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合



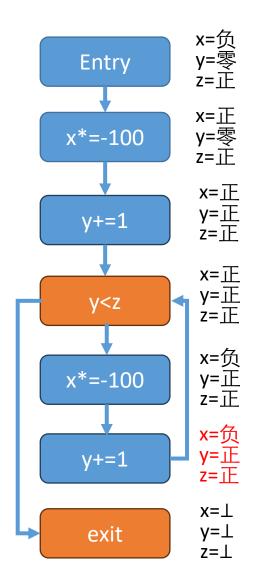


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合



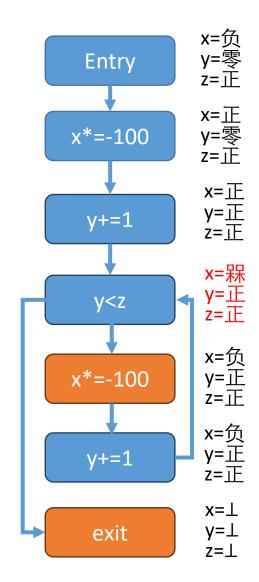


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合
- 反复迭代直到没有节点需要更新



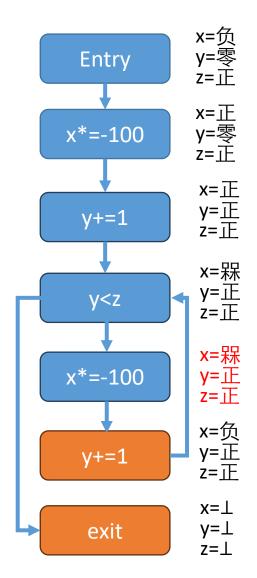


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合
- 反复迭代直到没有节点需要更新



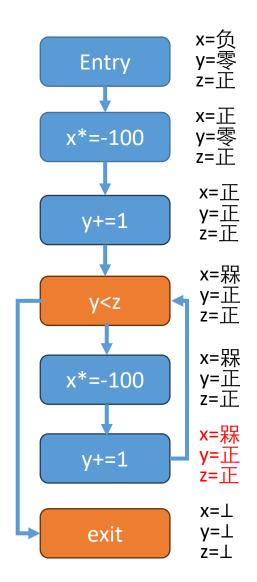


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合
- 反复迭代直到没有节点需要更新



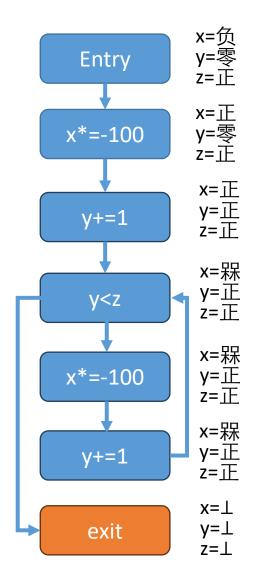


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合
- 反复迭代直到没有节点需要更新



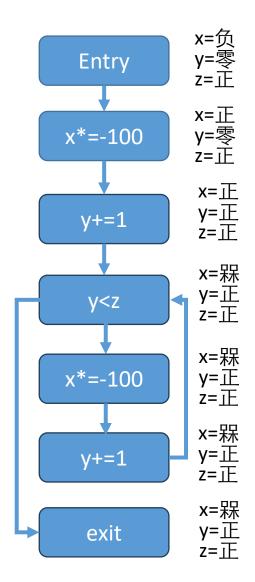


- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合
- 反复迭代直到没有节点需要更新





- 每次选择一个节点更新
- 如果值有变化,该节点的后继节点也需要加入 待更新集合
- 反复迭代直到没有节点需要更新





#### 符号分析-算法



- $\diamondsuit$ **S** = { $(s_x, s_y, s_z) | s_x, s_y, s_z \in \{\text{L}, \text{D}, \text{\$}, \text{\$}, \text{L}\}$ }
- 每个节点的值为**S**的一个元素,代表对应语句执行之后的抽象状态,用OUT 表示
  - 同时用IN表示语句执行之前的抽象状态
- 初始值
  - OUT<sub>entry</sub>=(负,零,正)
  - OUT<sub>其他节点</sub>=(⊥, ⊥, ⊥)
- 节点转换函数 $f_v$ :  $S \to S$ 
  - $f_{exit} = id$
  - $f_{$ 其他节点=根据相应语句进行计算
- 合并运算 $IN_v = \sqcup_{w \in pred(v)} OUT_w$
- 节点更新运算 $OUT_v = f_v(IN_v)$
- 如果某个节点的前驱节点发生了变化,则使用节点更新运算更新该节点的 附加值
- 如果没有任何节点的值发生变化,则程序终止。

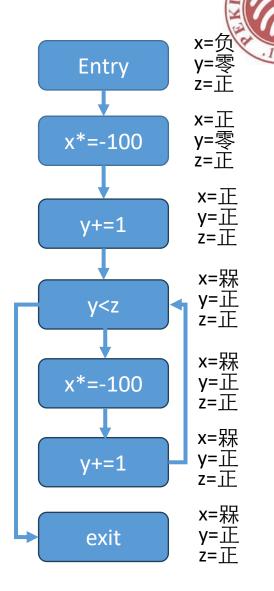
#### 符号分析实现算法



```
OUT_{entry} = I
\forall v \in (V - entry): OUT_v \leftarrow T
ToVisit ← succ(entry)
While(ToVisit.size > 0) {
 v ← ToVisit中任意节点
 ToVisit -= v
 IN_v \leftarrow \sqcup_{w \in pred(v)} OUT_w
 If(OUT_v \neq f_v(IN_v)) ToVisit U = succ(v)
 OUT_v \leftarrow f_v(IN_v)
```

#### 分析为什么是对的?

- 转换函数和合并函数可以 看做是定义了一组方程
  - OUT<sub>entry</sub>=(负,零,正)
  - $IN_v = \sqcup_{w \in pred(v)} DATA_w$
  - $OUT_v = f_v(IN_v)$
  - 其中v为entry之外的任意节 点
- 计算到不动点,意味着上述等式全部成立,即结果是方程的一组解



#### 符号分析正确性



- 如果分析正常结束,给定输入抽象值对应的任意 具体输入,程序执行到任意节点的状态一定包含 在该节点的抽象值中。
- 证明和分支的情况类似:
  - 该具体输入的执行产生一条路径。在路径长度上做归纳,证明路径结束位置的抽象值包括具体值。
  - 路径长度为1的时候,显然成立。



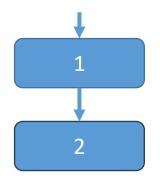
x=负 y=零 z=正

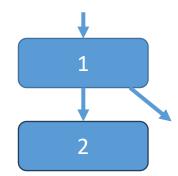
• 假设路径长度为k的时候成立,分三种情况讨论k+1的 情形

#### 符号分析正确性



- •情况1:路径末尾只有一个后继节点,没有分叉和合并
  - $OUT_2 = f_2(OUT_1)$
  - 转换函数正确时,该情形保证 正确
- 情况2: 路径末尾有分叉的情况
  - $OUT_2 = f_2(OUT_1)$
  - 同上,仍然正确

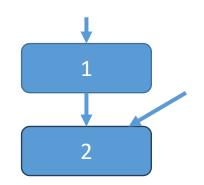




#### 符号分析正确性

UNIDER SINGLES

- •情况3:路径末尾有合并的情况
  - OUT<sub>2</sub> = f<sub>2</sub>(OUT<sub>1</sub> ⊔ 其他值)
  - □保证保留所有具体状态,所以具体状态仍然在f<sub>2</sub>的输入中



#### 数据流分析的收敛性



- 该算法保证终止(Terminating)吗?
  - 路径上有环的时候,是否会一直循环?
- 该算法一定合流(Confluent)吗?
  - 有多个节点可更新的时候,是否无论先更新哪个节点最后都会到达同样的结果?
- 终止+合流=收敛(Convergence)
- 数据流分析是保证收敛的,具体证明将在数据流分析框架部分介绍

#### 数据流分析一小结



- 近似方案1: 抽象状态代表程序的多个具体状态
- 近似方案2: 针对控制流节点编写转换函数
- 近似方案3:在控制流路径分叉时,复制抽象状态到所有分支
- 近似方案4:在控制流路径合并时,用□操作合并多个抽象状态

四种近似方案也代表着数据流分析的四种不精确性来源

#### 近似方案1的不精确



- 近似方案1: 抽象状态代表程序的多个具体状态
- 发生在需要将具体值集合映射到抽象值时

• 输入: x为正数或者负数

• 抽象值: x=槑

#### 近似方案2的不精确



- 近似方案2: 针对控制流节点编写转换函数
- 转换函数无法精确给出结果时

• 语句: x++

• 输入: x=正

• 输出: x=正

• 额外引入了x=1的不精确情况

#### 近似方案3的不精确



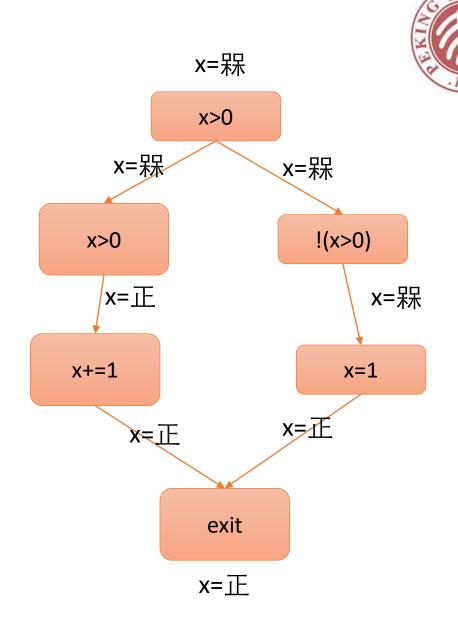
- 近似方案3:在控制流路径分叉时,复制抽象状态到所有分支
- 每个具体状态只能到达一个分支,形成不精确

x=槑
if (x>0) c1 else c2
到达c1的所有x都是正数
到达c2的所有x都是负数

x=正
if (x>0) c1 else c2
c1的抽象状态仍然是精确的
但没有状态能达到c2

# 解决方案

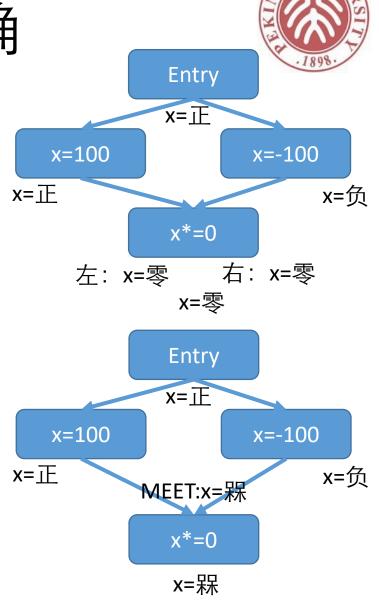
- 在每个分支添加节点,根据条件压缩抽象值
- 通常需要针对抽象 域专门设计,缺少 通用的方法
- 很多时候也难以压缩
  - 如右图else分支
  - 如x>y的情况
- 精度要求不高的场 合通常直接忽略分 支条件



近似方案4的不精确

近似方案4:在控制流路 径合并时,用□操作合并 多个抽象状态

- 合并的状态可能会引入不精确值
- •右下:引入NaN、零等不 精确值
- 右上:如果先计算\*0, 再合并,可以得到精确 答案



#### 设计数据流分析



- 近似方案1: 抽象状态代表程序的多个具体状态
  - 设计抽象域,对应的 $\alpha$ 、 $\gamma$ 函数和初始值
- 近似方案2: 针对控制流节点编写转换函数
  - 设计从基本语句导出转换函数的方法
- 近似方案3:在控制流路径分叉时,复制抽象状态到所有分支
  - 设计从条件导出压缩函数的方法(可选)
- 近似方案4:在控制流路径合并时,用□操作合并多个抽象状态
  - 设计□操作



对程序中任意语句,分析运行该语句后每个变量的值可能是由哪些语句赋值的,给出语句标号。要求上近似,即返回值包括所有可能的定值。

• 例:

1. a=100; 运行到1的时候a的定值是1

2. if (c > 0) 运行到2的时候a的定值是1

3. a = 200; 运行到3的时候a的定值是3

4. b = a; 运行到4的时候a的定值是3, b的定值是4

5. return a; 运行到5的时候a的定值是1,3,b的定值是4

#### 可达定值分析-抽象域



- 抽象域: 从变量到指针集合的映射
  - a->{1}, b->{}
  - a->{1, 3}, b->{4}
- 初始值: 所有变量都映射到空集
- 抽象值含义: 具体执行序列集合, 定值语句落在对应范围内
  - 具体执行序列: (语句编号,状态)构成的序列
  - $\gamma$ (a->{1, 3}, b->{4})
    - 表示从程序开头到当前节点的具体执行的集合
    - 其中
      - a的定值位置在1或者3或未定值
      - b的定值位置在4或未定值
    - 如:
      - 程序从a=1, b未初始化, c=0的状态开始执行
      - 则会走1, 2, 5的路径
      - 最后a在1定值,b未定值

2. if 
$$(c > 0)$$

3. 
$$a = 200$$
;

4. 
$$b = a$$
;

# 可达定值分析-合并操作



- 对应集合的并,即
  - (甲  $\sqcup$   $\angle$ )(x) =  $\exists$ (x)  $\sqcup$   $\exists$ (x)
  - 如:  $(a \to \{1,2\}, b \to \{\}) \sqcup (a \to \{1,3\}, b \to \{4\})$ =  $(a \to \{1,2,3\}, b \to \{4\})$
- 正确性: 甲或者乙所包含的任意具体执行过程仍然包括在(甲□乙)中

# 可达定值分析-节点转换函数



- $f_v(\mathbb{P})(x) = (\mathbb{P}(x) \text{KILL}_v^x) \cup GEN_v^x$ 
  - 对于赋值语句x=...
    - KILL\*\* ={所有赋值给x的语句编号}
    - *GEN*<sub>v</sub> ={当前语句编号}
  - 对于其他语句
    - KILL $_v^x = GEN_v^x = \{\}$
- 正确性:输入包含的具体执行序列加下一步仍然包括在输出中
- $f(\Psi) = (\Psi KILL) \cup GEN$ 又叫数据流分析的标准型

#### 数据流分析实现算法



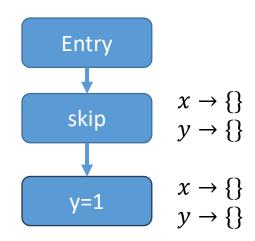
```
OUT_{entry} = I
\forall v \in (V - entry): OUT_v \leftarrow
ToVisit \leftarrow V - entry
While(ToVisit.size > 0) {
 v ← ToVisit中任意节点
 To Visit -= v
 IN_v \leftarrow \sqcup_{w \in pred(v)} OUT_w
 If(OUT<sub>v</sub> \neq f<sub>v</sub>(IN<sub>v</sub>)) ToVisit U= succ(v)
 OUT_v \leftarrow f_v(IN_v)
```

为什么?

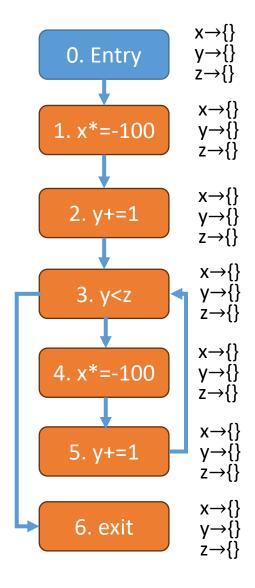
#### 数据流分析实现算法



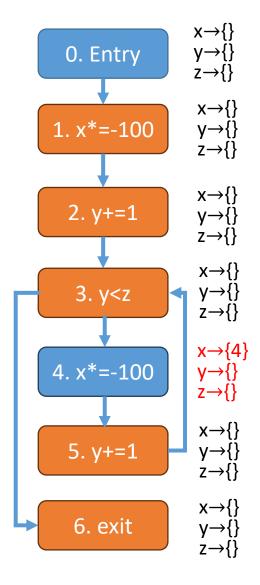
- 如果某个初始值在更新过程中没有被改变,后续节点也不会被更新
- 符号分析不存在这个问题,因为初始值 不变意味着对应节点是死代码
- 可达定值分析也可以改成这种方式
  - 方式一: 一开始就假设所有变量被entry定值
  - 方式二: 设置特殊的抽象值作为初值
- 由于通用性更强,上页代码是数据流分析的标准代码
  - 之后会看到其他需要加入所有节点的情况
  - 通过特定选择顺序可以部分避免无效更新, 如LIFO



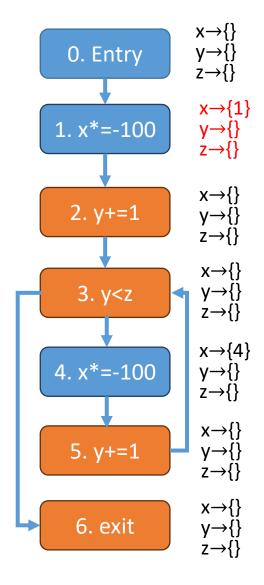




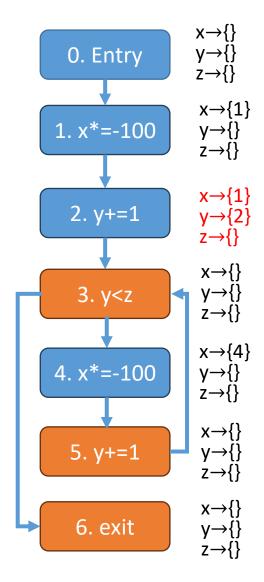




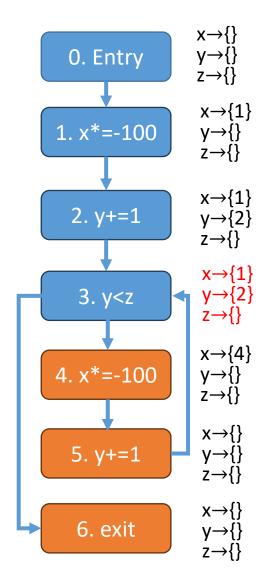




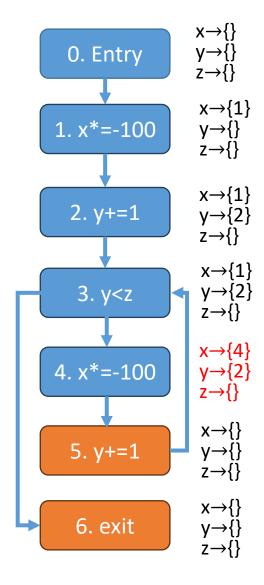




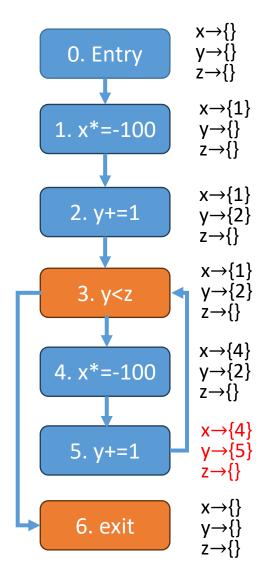




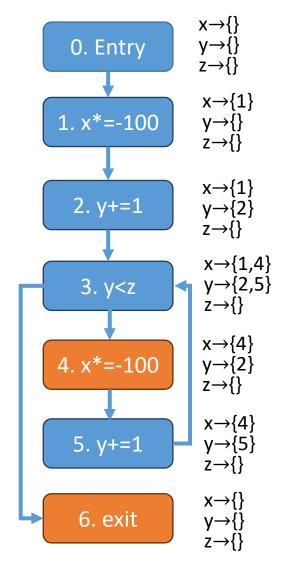




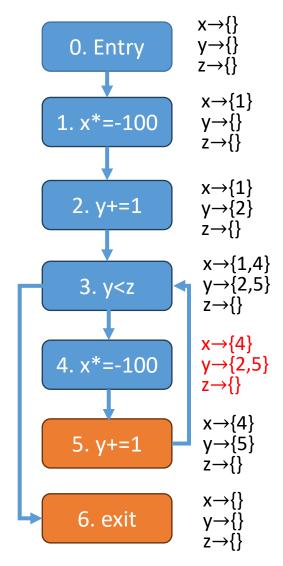




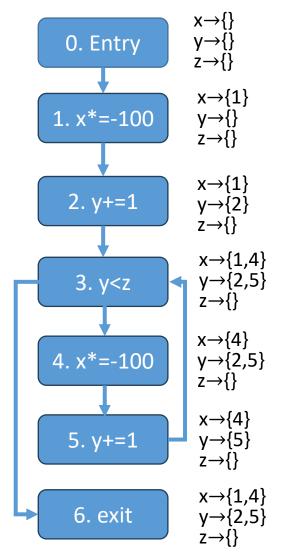












#### 可达定值分析正确性



给定从头开始的任意具体执行序列,结束状态对 应的变量定值位置都在抽象值的范围内

• 证明: 在具体执行序列的长度上做归纳

# 可达定值分析一一小结



- 和符号分析的关键不同点
  - 抽象值对应具体执行序列的集合
  - 在分析开头加入所有其他节点到ToVisit
- 由于更通用,标准数据流分析也按照以上两种情况定义

# 可用表达式(available expression)分析



- 给定程序中某个位置p,如果从入口到p的所有 路径都对表达式exp求值,并且最后一次求值后 该表达式的所有变量都没有被修改,则exp称作p 的一个可用表达式。给出分析寻找可用表达式。
  - 要求下近似
  - 例:
    - 1. a=c+(b+10);
    - 2. if (a>b)
    - 3. c = a+10;
    - 4. return a;

1运行结束的时候可用表达式是b+10、c+(b+10)

2运行结束的时候可用表达式是b+10、c+(b+10)

3运行结束的时候可用表达式是b+10、a+10

4运行结束的时候可用表达式是b+10

# 可用表达式分析一一抽象域



• 抽象值:表达式的集合

• 初始值:程序中表达式的全集

抽象值含义:对应从头到当前位置的具体执行序列的集合,其中可用表达式是当前位置抽象值的超集

# 可用表达式分析一一合并



- 集合交
- 正确性: 甲或者乙所包含的任意具体执行过程仍然包括在(甲□乙)中

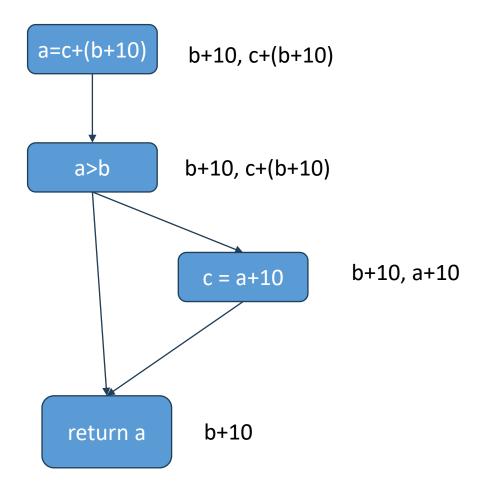
# 可用表达式分析-节点转换函数



- $f_v(甲) = (甲 KILL_v) \cup GEN_v$ 
  - 对于赋值语句x=...
    - KILL<sub>v</sub> ={所有包含x的表达式}
    - $GEN_v = \{$ 当前语句中求值的不含x的表达式 $\}$
  - 对于其他语句
    - KILL<sub>v</sub>={}
    - $GEN_v$ ={当前语句中求值的表达式}
- 正确性:输入包含的具体执行序列加下一步仍然 包括在输出中







#### 可用表达式分析正确性



给定从头开始的任意具体执行序列,结束状态对 应的可用表达式是抽象值的超集

• 证明: 在具体执行序列的长度上做归纳

#### 可用表达式分析-小结



- 和之前的分析不同
  - 分析是下近似,即抽象域包含的为具体域的子集
  - 初始值为全集
  - 合并操作为求交
- 标准数据流框架同时提供对上近似和下近似的支持

# 活跃变量分析(Liveness Analysis)

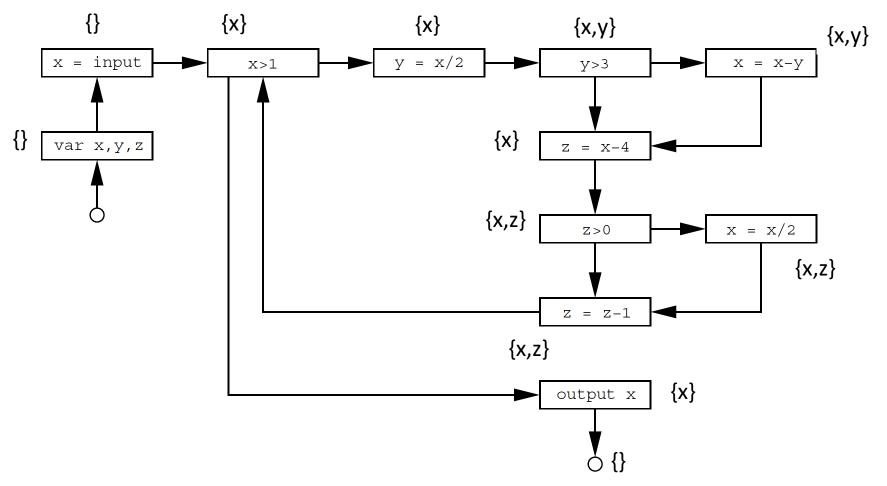


- 活跃变量: 给定程序中的某条语句s和变量v,如果在s执行前保存在v中的值在后续执行中还会被读取就被称作活跃变量
- 第四行的x和y是否为活跃变量?
  - x活跃, y不活跃
- 第八行的x和z呢?
  - x和z都活跃
- 活跃变量分析: 返回所有可能的活跃变量
  - ・上近似

- 1. var x,y,z;
- 2. x = input;
- 3. while (x>1) {
- 4. y = x/2;
- 5. if (y>3) x = x-y;
- 6. z = x-4;
- 7. if (z>0) x = x/2;
- 8. z = z-1;
- 9. }
- 10. output x;

# 活跃变量分析-例子





# 活跃变量分析一一抽象域



• 抽象值: 变量的集合

• 初始值: 空集

抽象值含义:对应从当前位置开始的任意长度的 具体执行序列的集合

• 因为程序有可能会无限执行,不能定义为到exit结束的序列

# 活跃变量分析一一合并



- 集合并
- 正确性: 甲或者乙所包含的任意具体执行过程仍然包括在(甲 □ 乙)中

# 活跃变量分析-节点转换函数



- $f_v(\mathbb{P}) = (\mathbb{P} \setminus KILL_v) \cup GEN_v$ 
  - $GEN_v = v$ 中读取的所有变量

• 
$$KILL_v = \begin{cases} \{x\} & v \coloneqq \mathbf{x} = \exp; \\ \{x\} & v \coloneqq \text{int } \mathbf{x}; \\ \{\} & otherwise \end{cases}$$

• 正确性:输入包含的具体执行序列加上一步仍然包括在输出中

# 活跃变量分析实现算法



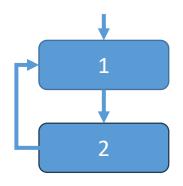
```
IN_{exit} = I
\forall v \in (V - exit): IN_v \leftarrow T
ToVisit \leftarrow V - exit
While (To Visit. size > 0) {
 v ← ToVisit中任意节点
 To V is it -= v
 OUT_v \leftarrow \sqcup_{w \in succ(v)} IN_w
 If(IN<sub>v</sub> \neq f<sub>v</sub>(OUT<sub>v</sub>)) ToVisit \cup= pred(v)
 IN_v \leftarrow f_v(OUT_v)
         交换IN和OUT, 交换pred和succ, 交换exit和entry
         等价于把数据流的所有箭头方向交换,exit和entry后应用原算法
```

如果引入单独的初值, 是否还需要加入所有 节点





• 需要,可能会有不能到达exit的执行序列



#### 活跃变量分析-正确性



和之前的问题不同,因为序列不一定在exit结束, 所以不能从exit出发反向做归纳

- 给定任意长度的具体执行序列,以开始位置看, 在该序列上活跃的变量都在开始位置的抽象值中
- 证明: 从序列的结束位置开始反向对长度做归纳
- 该形式也是更通用的形式

#### 活跃变量分析一小结



- 和之前的分析不同
  - 分析是反向开始
  - 程序有可能不结束,也就是说执行序列不一定到达 exit
    - 和之前执行序列一定从entry开始不同
    - 需要一开始将所有exit之外节点加入toVisit
    - 正确性要从一段任意长度的执行序列定义

# 作业:繁忙表达式分析(very busy expression)



- 繁忙表达式: 从执行某个程序节点之前开始, 在其中变量被修改之前, 一定会被读取的表达式
- 繁忙表达式分析: 找到每个程序节点的繁忙表达式
  - 要求下近似
  - 如:
    - 1. if (a > b)
    - 2. x=b-a
    - 3. y=x-y+(a+b+b)
    - 4. else
    - 5. y=b-a
    - 6. x=x-y+(a+b)
  - 在第一行, b-a, a+b, a>b为繁忙表达式
- 请设计繁忙表达式分析。请给出分析方向、抽象域设计(抽象值集合、γ、初值)、转换函数、合并操作,并简要讨论分析正确性。

#### 参考资料



- 《编译原理》第9章
- Lecture Notes on Static Analysis
  - https://cs.au.dk/~amoeller/spa/