

软件分析

过程间分析

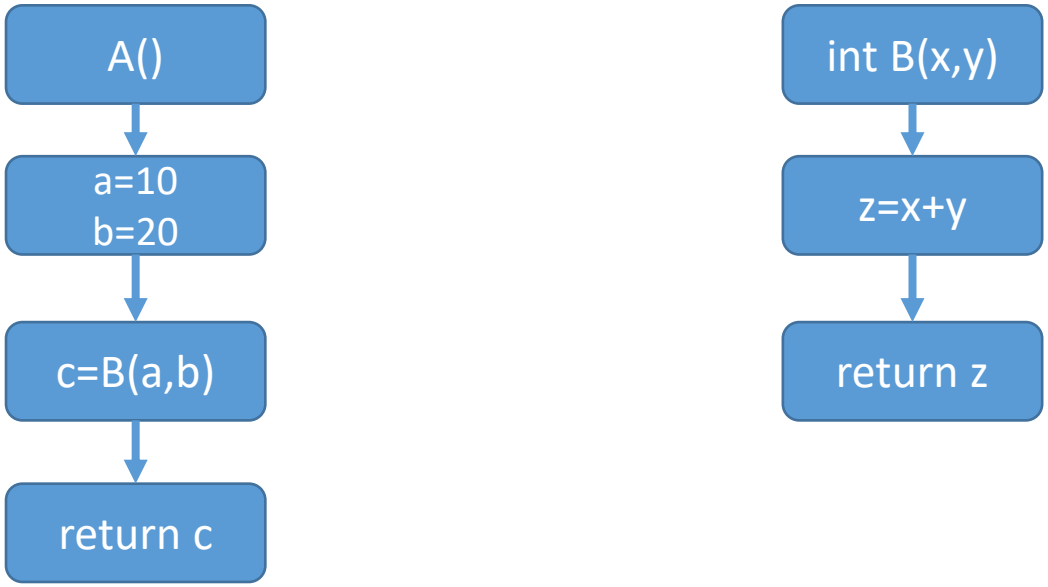
熊英飞
北京大学

过程间分析



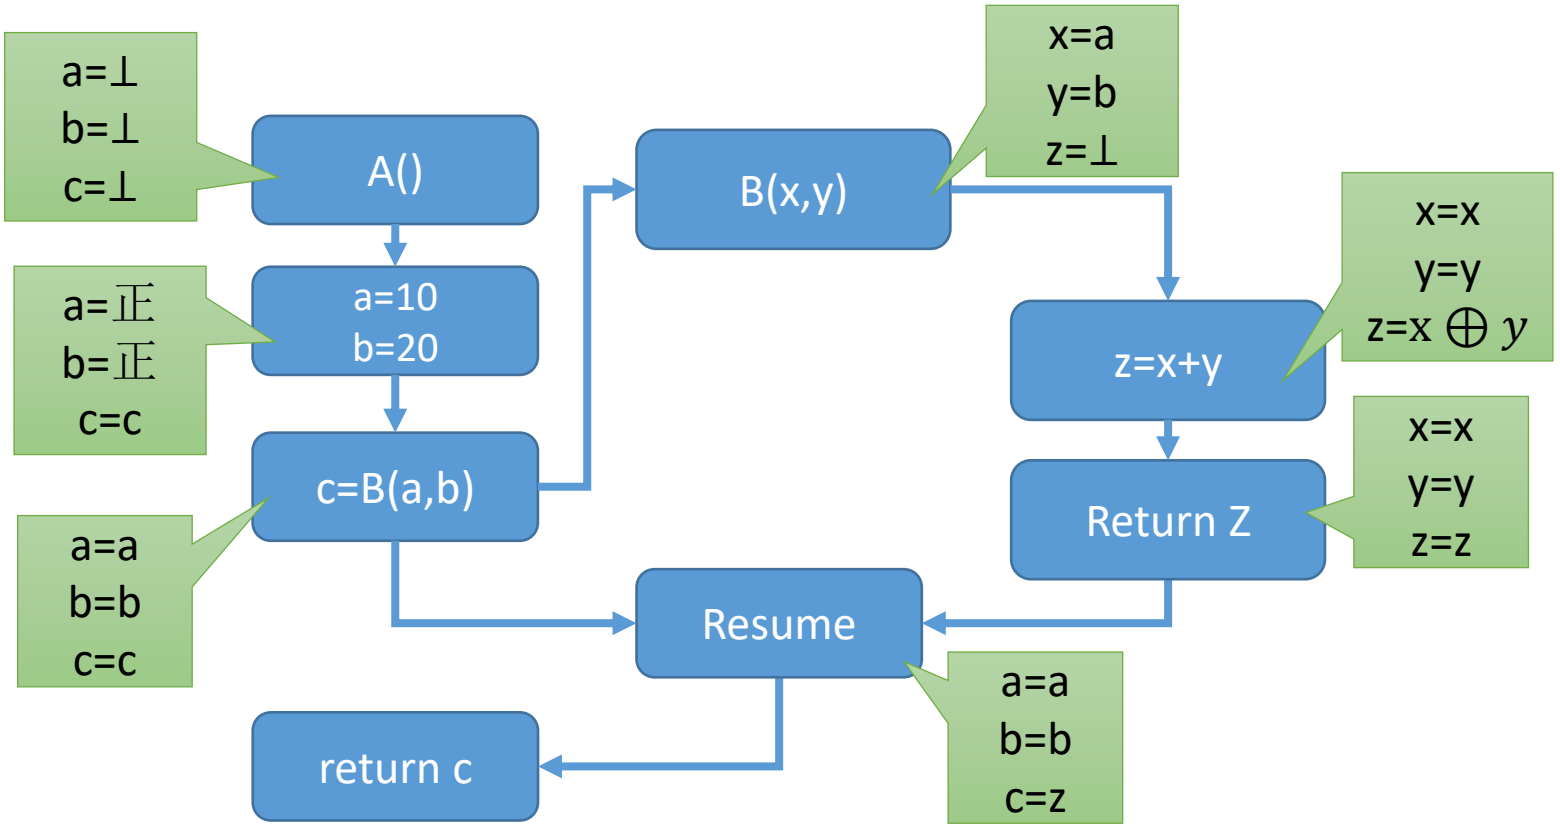
- 过程内分析Intra-procedural Analysis
  - 只考虑过程内部语句，不考虑过程调用
  - 目前的所有分析都是过程内的
- 过程间分析Inter-procedural Analysis
  - 考虑过程调用的分析
  - 有时又称为全程序分析Whole Program Analysis
  - 对于C, C++等语言，有时又称为链接时分析Link-time Analysis

过程间分析-示例



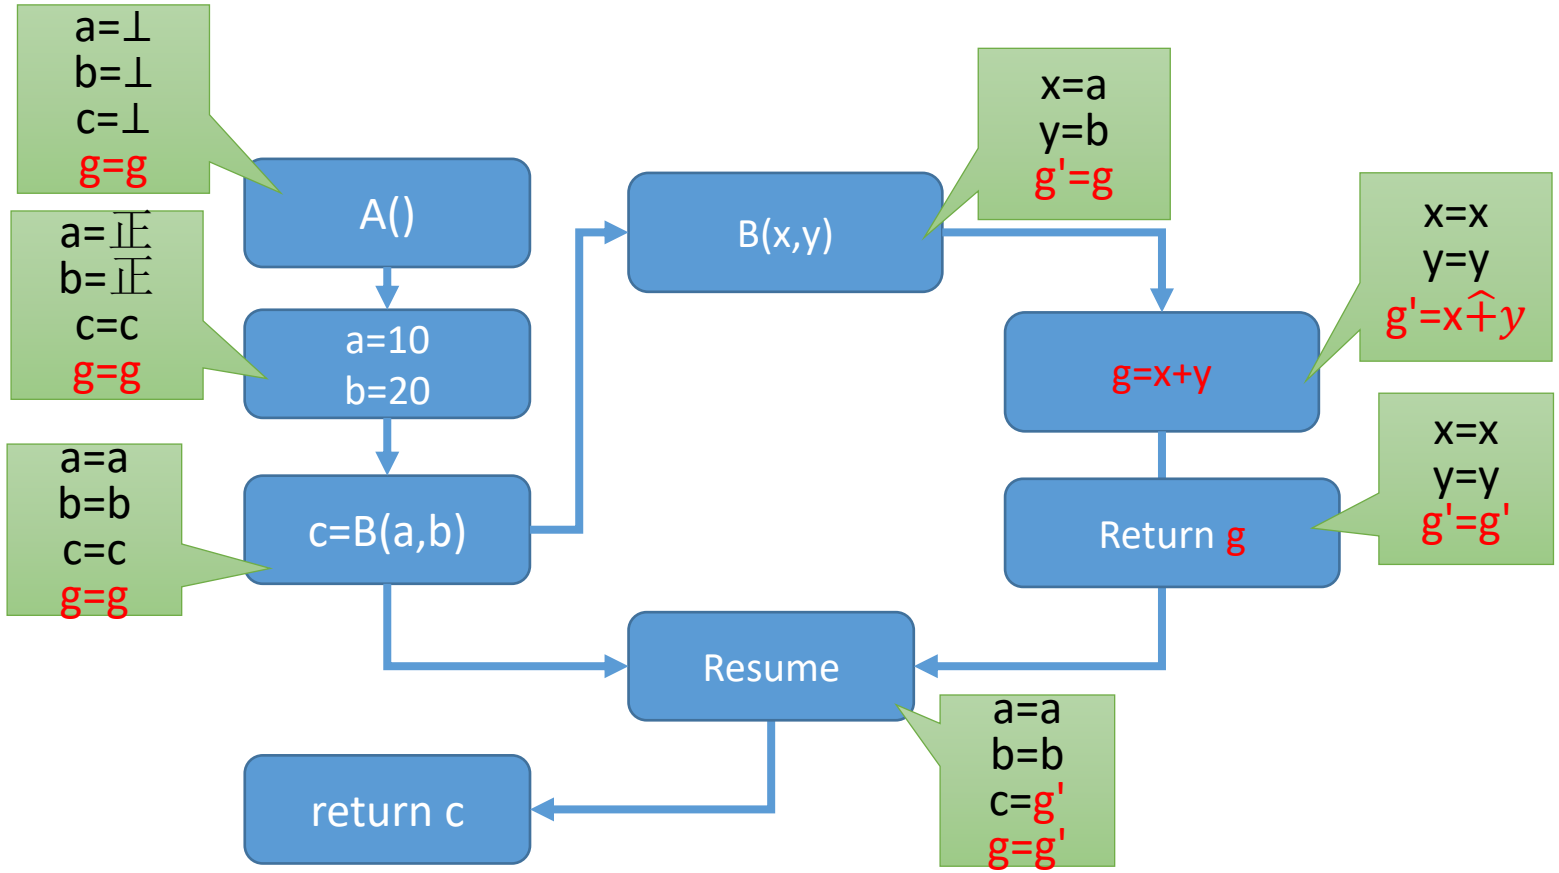
过程间分析-基本思路

- 对不同过程采用不同抽象域
- 在调用和返回的时候添加结点来转换信息
  - 这样的控制流图称为Super CFG



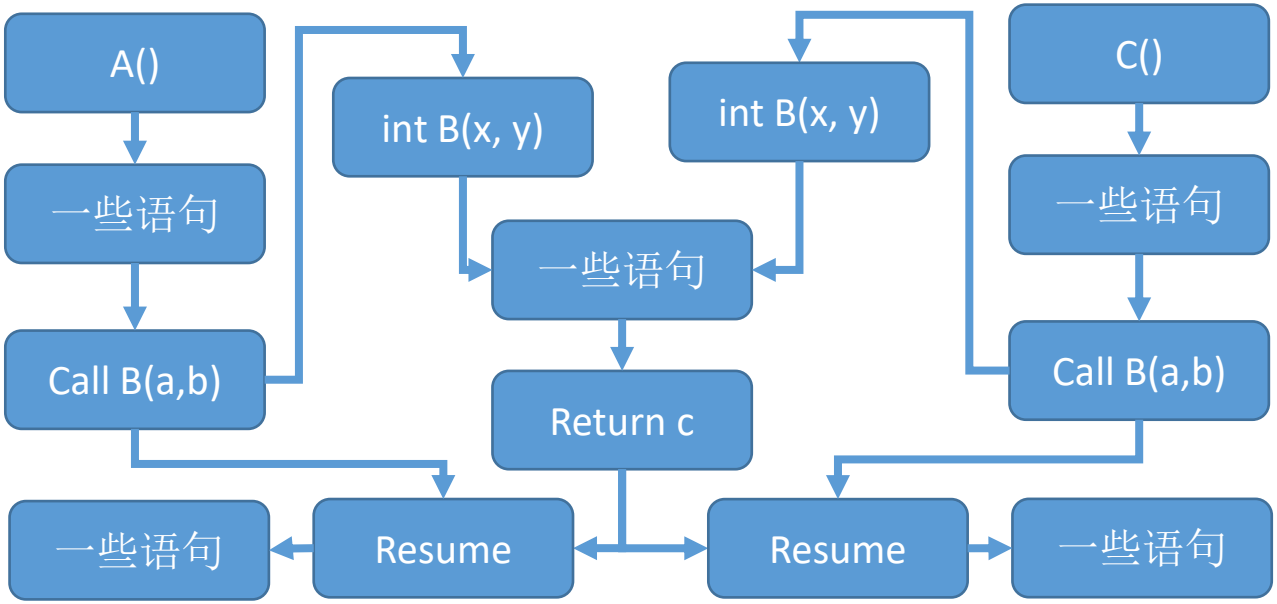
全局变量

- 全局变量需要加到所有使用的过程和这些过程的直接和间接调用者中
- 全局变量带来的开销是过程间静态分析必须考虑的问题



过程间分析-精度问题

- 上述分析方法是否有精度损失?



- 会考虑不可能路径上的执行轨迹
- 会将A()函数的分析结果引入C()函数，反之亦然

示例：常量分析



- 判断在某个程序点某个变量的值是否是常量

```
int id(int a) { return a; }
void main() {
  int x = id(100);
  int y = id(200);
}
```

- main执行结束时，x和y都应该是常量，但在super CFG中分析不出来这样的结果

上下文敏感性
Context-sensitivity

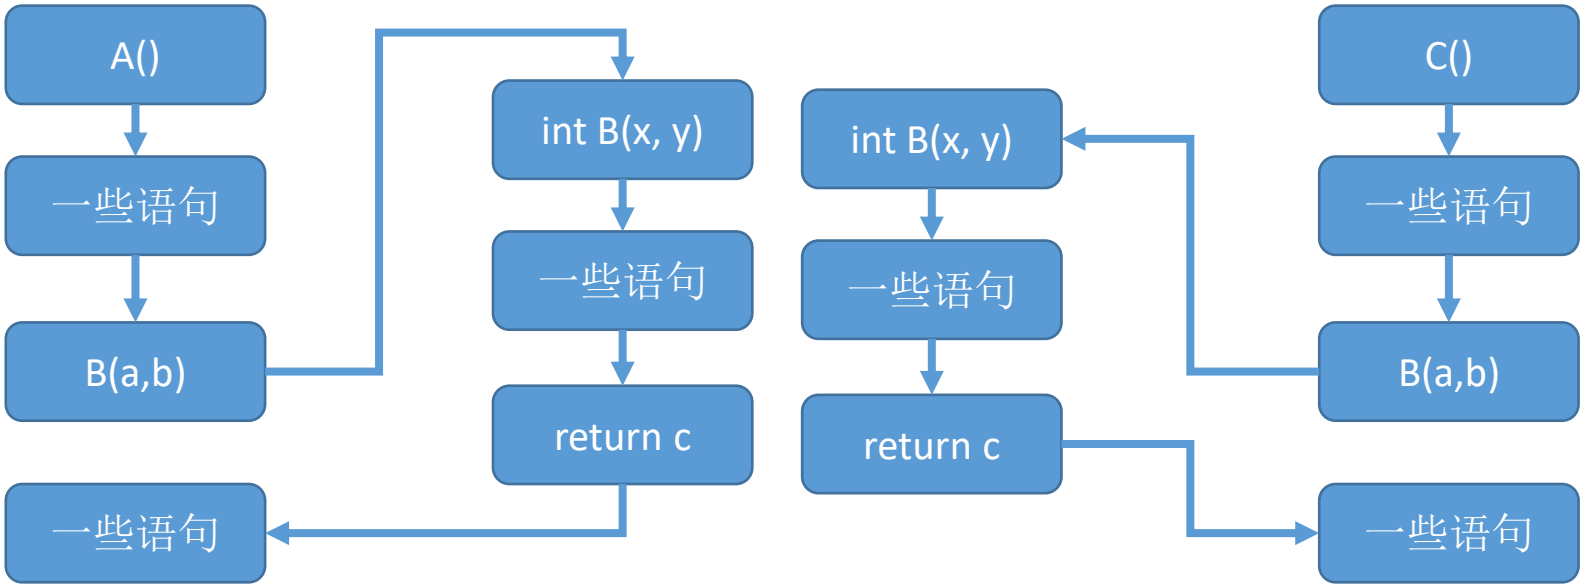


- 上下文非敏感分析Context-insensitive analysis
  - 在过程调用的时候忽略调用的上下文
- 上下文敏感分析Context-sensitive analysis
  - 在过程调用的时候考虑调用的上下文

基于克隆的上下文敏感分析
Clone-based Context-Sensitive Analysis

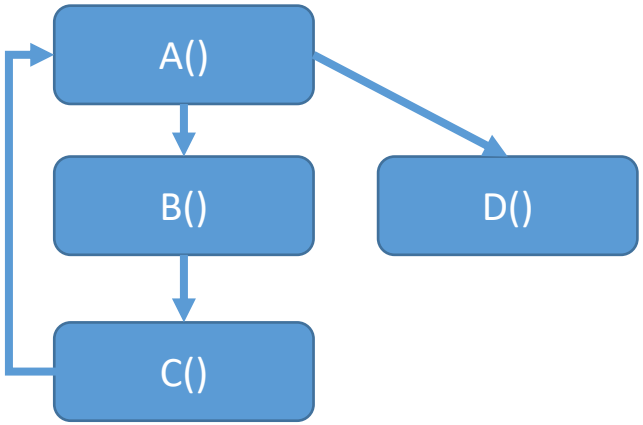


- 给每一处调用创建原函数的一份复制



Call Graph调用图

- 结点表示过程，边表示调用关系



基于克隆的上下文敏感分析



- 练习1：给定下面的程序，请画出克隆之后的函数调用图
  - p() {return q()*q();}
  - q() {return r()+r();}
  - r() {return 100;}

基于克隆的上下文敏感分析



- 练习1：给定下面的程序，请画出克隆之后的函数调用图
  - p() {return q()*q();}
  - q() {return r()+r();}
  - r() {return 100;}

- 练习2：能否画出下面程序的克隆后的函数调用图?
  - p(int n) {return n*p(n-1);}

基于克隆的上下文敏感分析



- 调用栈决定了不同的返回位置
- 但调用栈的可能长度是无限的
- 主要问题1：如果有深层次重复函数，就会出现指数爆炸
- 主要问题2：递归调用无法处理

基于克隆的上下文敏感分析

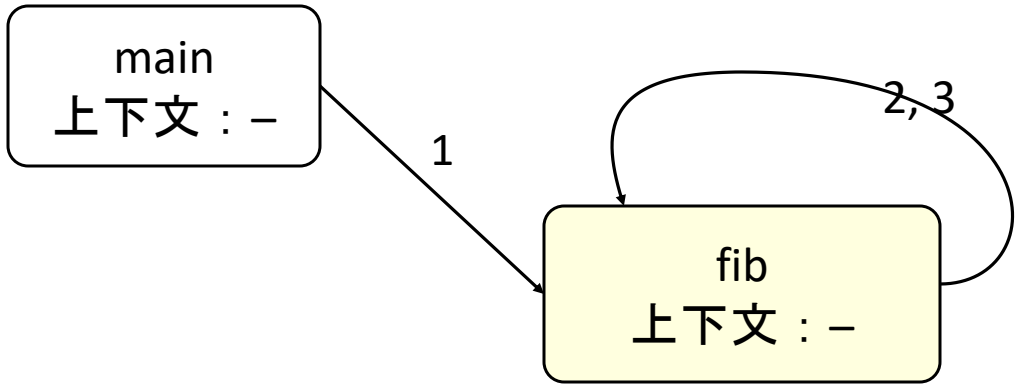


- 解决方案：
  - 对调用栈做抽象
  - 只使用最近k次调用（只考虑调用栈中的调用，即调用了还没有返回的）区分上下文
  - 如果最近k次调用的位置都相同，则不复制，否则复制

Fibonacci函数示例 --上下文非敏感

```
main() {
  1: fib(7);
}

fib(int n) {
  if (n <= 1)
    x := 1;
  else {
    2: y := fib(n-1);
    3: z := fib(n-2);
    x := y+z;
  }
  return x;
}
```

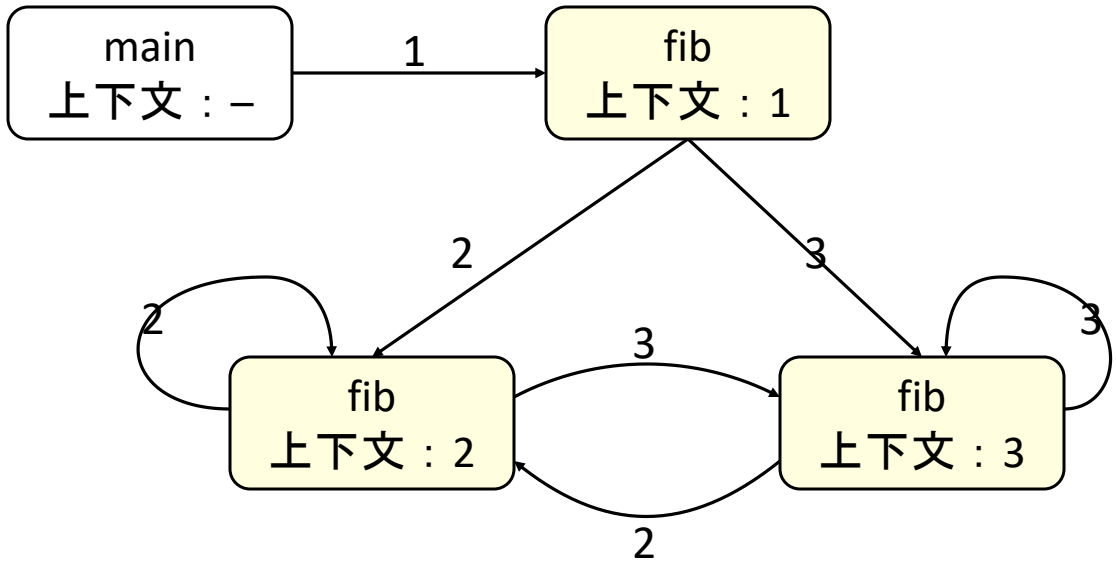


fib有三个可能的返回点

Fibonacci函数示例 --深度1的Clone-based analysis

```
main() {
  1: fib(7);
}

fib(int n) {
  if (n <= 1)
    x := 1;
  else {
    2: y := fib(n-1);
    3: z := fib(n-2);
    x := y+z;
  }
  return x;
}
```



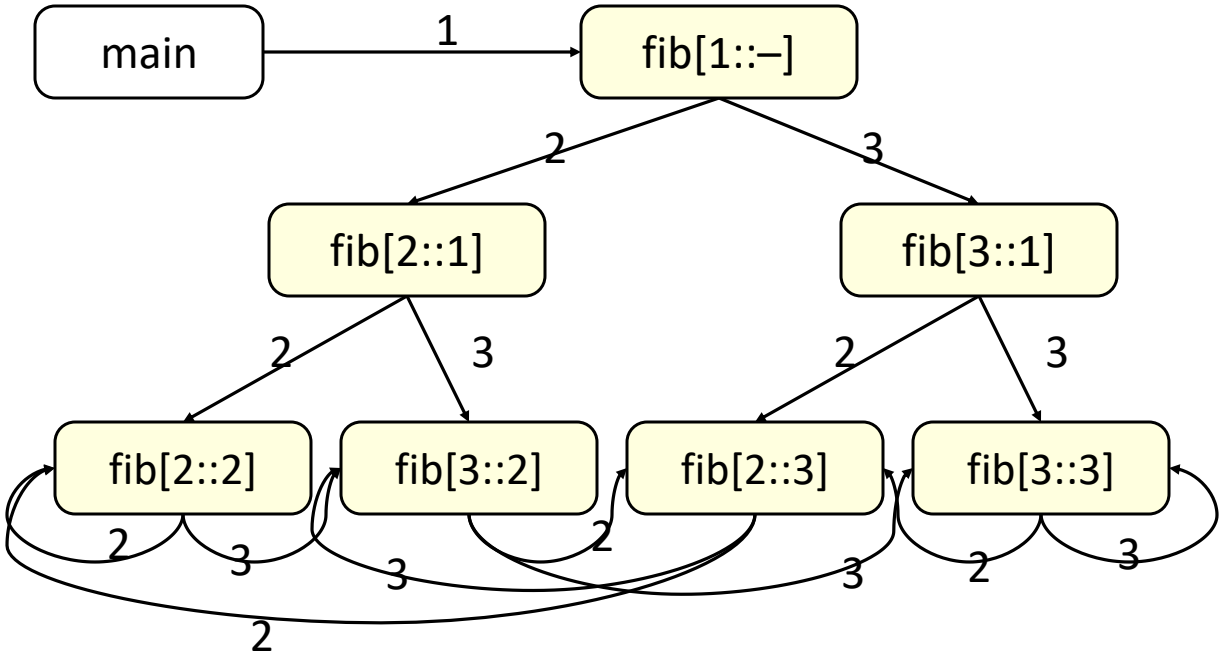
fib[1]的返回已经精确，剩下两个也比之前精确

Fibonacci函数示例 --深度2的Clone-based analysis

```
main() {
  1: fib(7);
}

fib(int n) {
  if (n <= 1)
    x := 1;
  else {
    2: y := fib(n-1);
    3: z := fib(n-2);
    x := y+z;
  }
  return x;
}
```

调用图（每个结点代表一份控制流图）

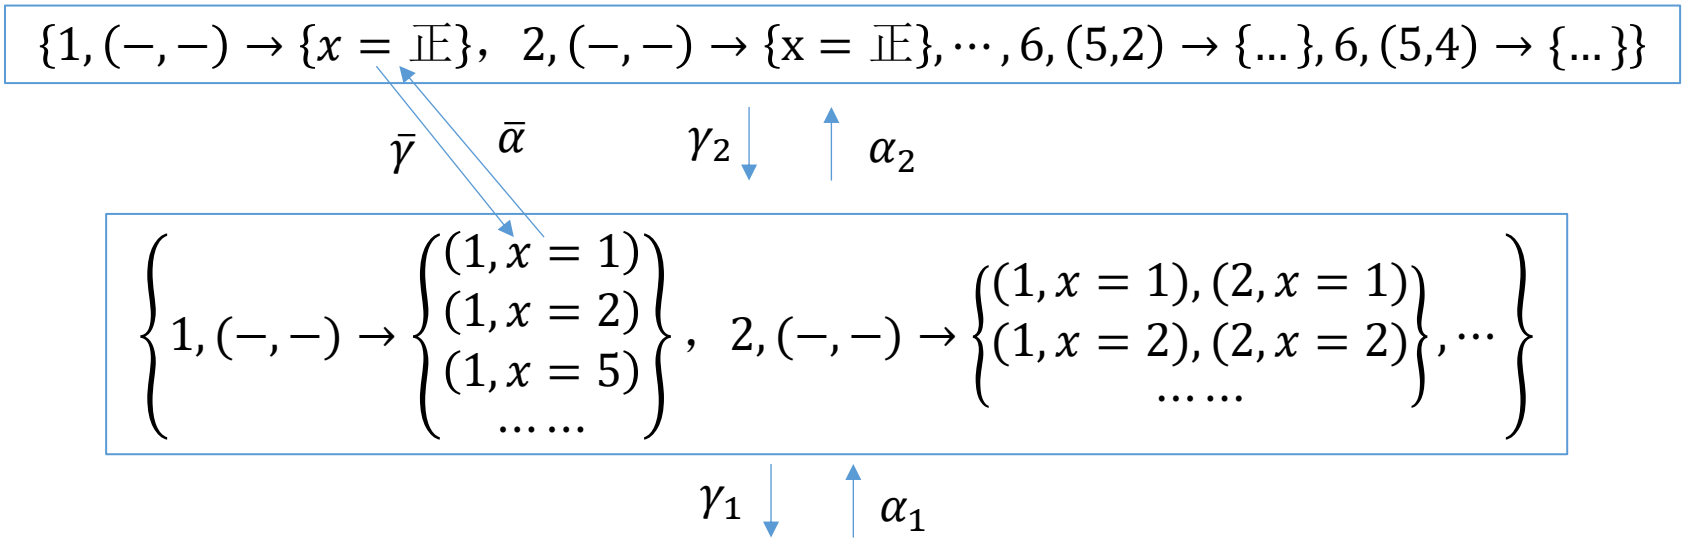


其他可能的上下文



- 基于函数名字而不是调用位置的上下文
  - 在Fib的例子中，2::2和2::3都变成了fib::fib
  - 不如调用位置精确，但能减少复制量
- 基于调用对象的上下文
  - 在OO语言中，对于x.p()的调用，根据x指向的对象或对象的类型区分上下文
  - 可以对OO函数重载进行一些更精细的分析
  - 也叫做对象敏感性（Object Sensitivity）或类型敏感性（Type Sensitivity）
- 基于系统状态的上下文
  - 根据分析需要，对系统的当前状态进行分类
  - 当函数以不同状态调用时，对函数复制

从抽象解释的角度


{1, (−, −) → {x = 正}, 2, (−, −) → {x = 正}, ⋯, 6, (5,2) → {…}, 6, (5,4) → {…}}
γ̄
ᾱ
γ2
α2
{1, (−, −) → {(1, x = 1), (1, x = 2), (1, x = 5), ……}, 2, (−, −) → {(1, x = 1), (2, x = 1), (1, x = 2), (2, x = 2), ……}, ⋯}
γ1
α1
{(1, ( ), x = 1), (2, ( ), x = 1), (5, (2), x = 2), (6, (5,2), x = 2)
(1, ( ), x = 2), (2, ( ), x = 2), (5, (2), x = 3), (6, (5,2), x = 3)
(1, ( ), x = 5), (3, (3), x = 5), (4, ( ), x = 6), (5, (4), x = 15), (6, (5,4), x = 15)
……}

克隆背后的主要思想



- 原始数据流分析按结束的控制流节点对具体直接轨迹分类，每类对应一个抽象值
  - 标准控制流图
- 流非敏感分析不分类，总共只有一个抽象值
  - 所有节点合并成一个的控制流图
- 上下文敏感进一步用最近k次调用来分类
  - 每个节点基于上下文分裂成多个

内联Inline



- 另一种实现克隆的方法是内联
- 内联：把被调函数的代码嵌入到调用函数中
- 实际效果和不限深度的克隆等效
  - 也无法处理递归调用的情况

精确的上下文敏感分析



- 精确的上下文敏感分析
  - =考虑最近任意多次调用的上下文
  - =对于任意分析中考虑的执行轨迹，轨迹中的调用边和返回边全部匹配

- 能否做到精确的上下文敏感分析?
  - 历史上提出多种不同的模型
    - CFL可达性分析
    - 函数摘要技术

CFL可达性分析

- 1995年由Reps等人提出
  - 理解上比较直观
  - 能够优化出高效算法
  - 能覆盖大部分具备分配性的数据流分析（但不能覆盖所有已有方法）
  - 基于该模型讨论清楚了若干可判定性问题





发明人：威斯康星大学
Thomas Reps教授
Susan Horwitz教授

Dyck-CFL

括号匹配的上下文无关语言

$S \rightarrow \{_1\ S\ \}_1$

$\quad | \ \{_2\ S\ \}_2$

$\quad | \ \ldots$

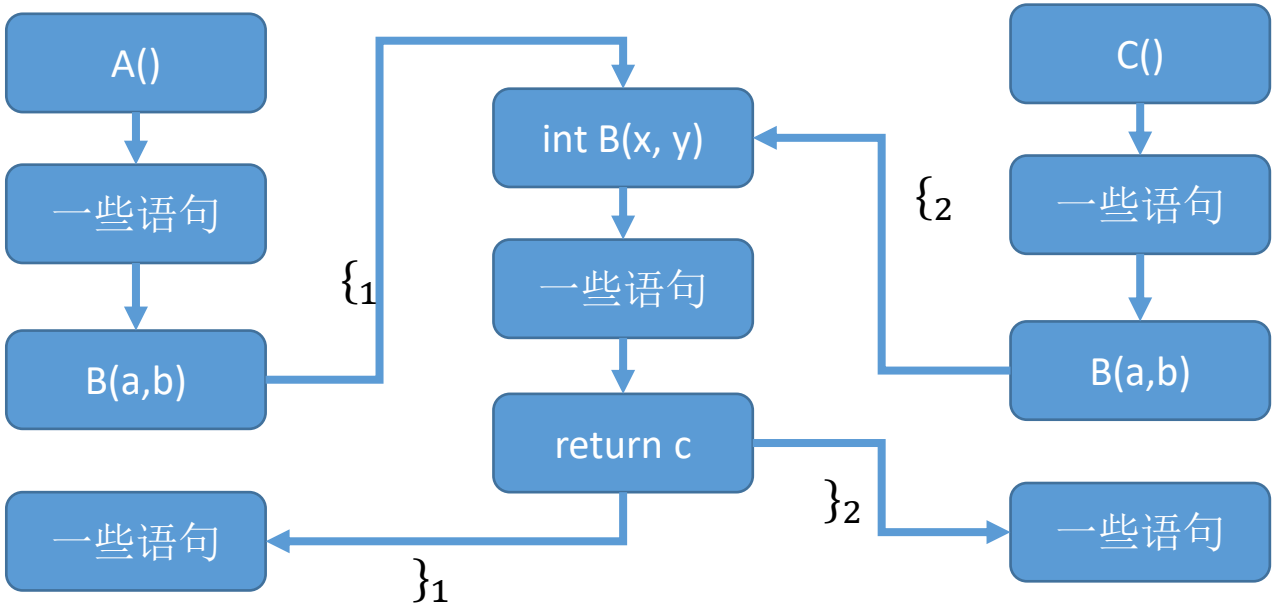
$\quad | \ SS$

$\quad | \ \epsilon$

注意区分上下文无关语言和上下文敏感性中的上下文

Dyck-CFL与上下文敏感性

- 给系统中的每一处调用分配唯一一对括号



- 给定一条路径，如果该路径上的符号组成Dyck-CFL的句子，则该路径的调用返回边都是匹配的

复习：数据流分析的分配性 Distributivity



- 什么叫数据流分析的分配性?
- 一个数据流分析满足分配性，如果
  - $\forall v \in V, x, y \in S: f_v(x) \sqcup f_v(y) = f_v(x \sqcup y)$
- 符号分析是否满足分配性?
- GEN/KILL标准型$f(S) = (S - KILL) \cup \text{GEN}$是否满足分配性?

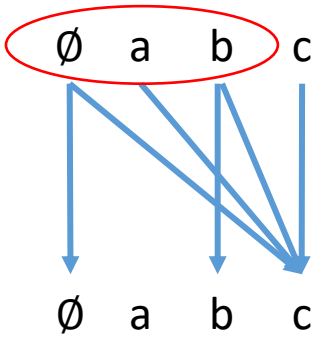
数据流分析的分配性



- 推论
  - 给定任意满足分配性的数据流分析X，其entry结点的初值是I^X。
  - 令Y和Z为仅有初值不同的数据流分析，其中Y和Z的初值分别是I^Y、I^Z，且$I^X = I^Y \sqcup I^Z$。
  - 令OUT_v^X为通过X分析得出的v结点的值
  - 则：$\mathrm{OUT}_v^X = \mathrm{OUT}_v^Y \sqcup \mathrm{OUT}_v^Z$
- 证明
  - 在任意执行路径上，结论成立
  - 根据数据流分配性的性质，在所有执行路径上，结论成立

转换函数vs图可达性

- 对于可分配函数f(X)=(X-{a})∪{c}，其中X为{a,b,c}的子集
- 可以表示成图

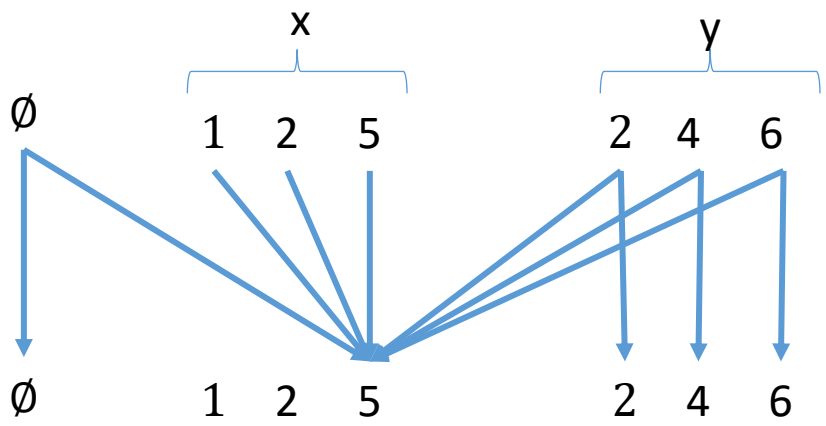


图中的非ø元素称为事实集，要求事实集的幂集刚好组成半格除了⊥ 以外的元素集合

- 求解f({a,b})变成了从 {ø,a,b}出发的可达性问题
  - ø为特殊添加，要求ø → ø的边始终存在，以应对结果为空集的情况
- 结合上页推论我们可以把整个数据流分析转成可达性问题

变量值有关的分析

- 抽象域为各个变量的抽象域的笛卡尔乘积
- 事实集为<变量，单变量事实>的二元组
- 例：可达定值分析



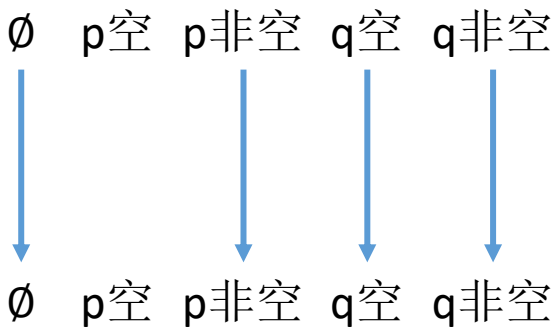
5: x=-y

非集合的分析

- 抽象域不是由集合组成的情况也可以找到事实集
- 比如符号分析，可以选择“正、负、零”三个值
  - 改方式比原符号分析更精确，因为存在{正,零}这样的组合
- 但仍然需要分配性来保证结果正确
  - 上述符号分析方式对所有一元运算可保证分配性
  - 但二元运算就不行，如x=x+y
    - $f(\{(x, 正)\}) = \emptyset$
    - $f(\{(y, 正)\}) = \{(y, 正)\}$
    - $f(\{(x, 正), (y, 正)\}) = \{(x, 正), (y, 正)\}$

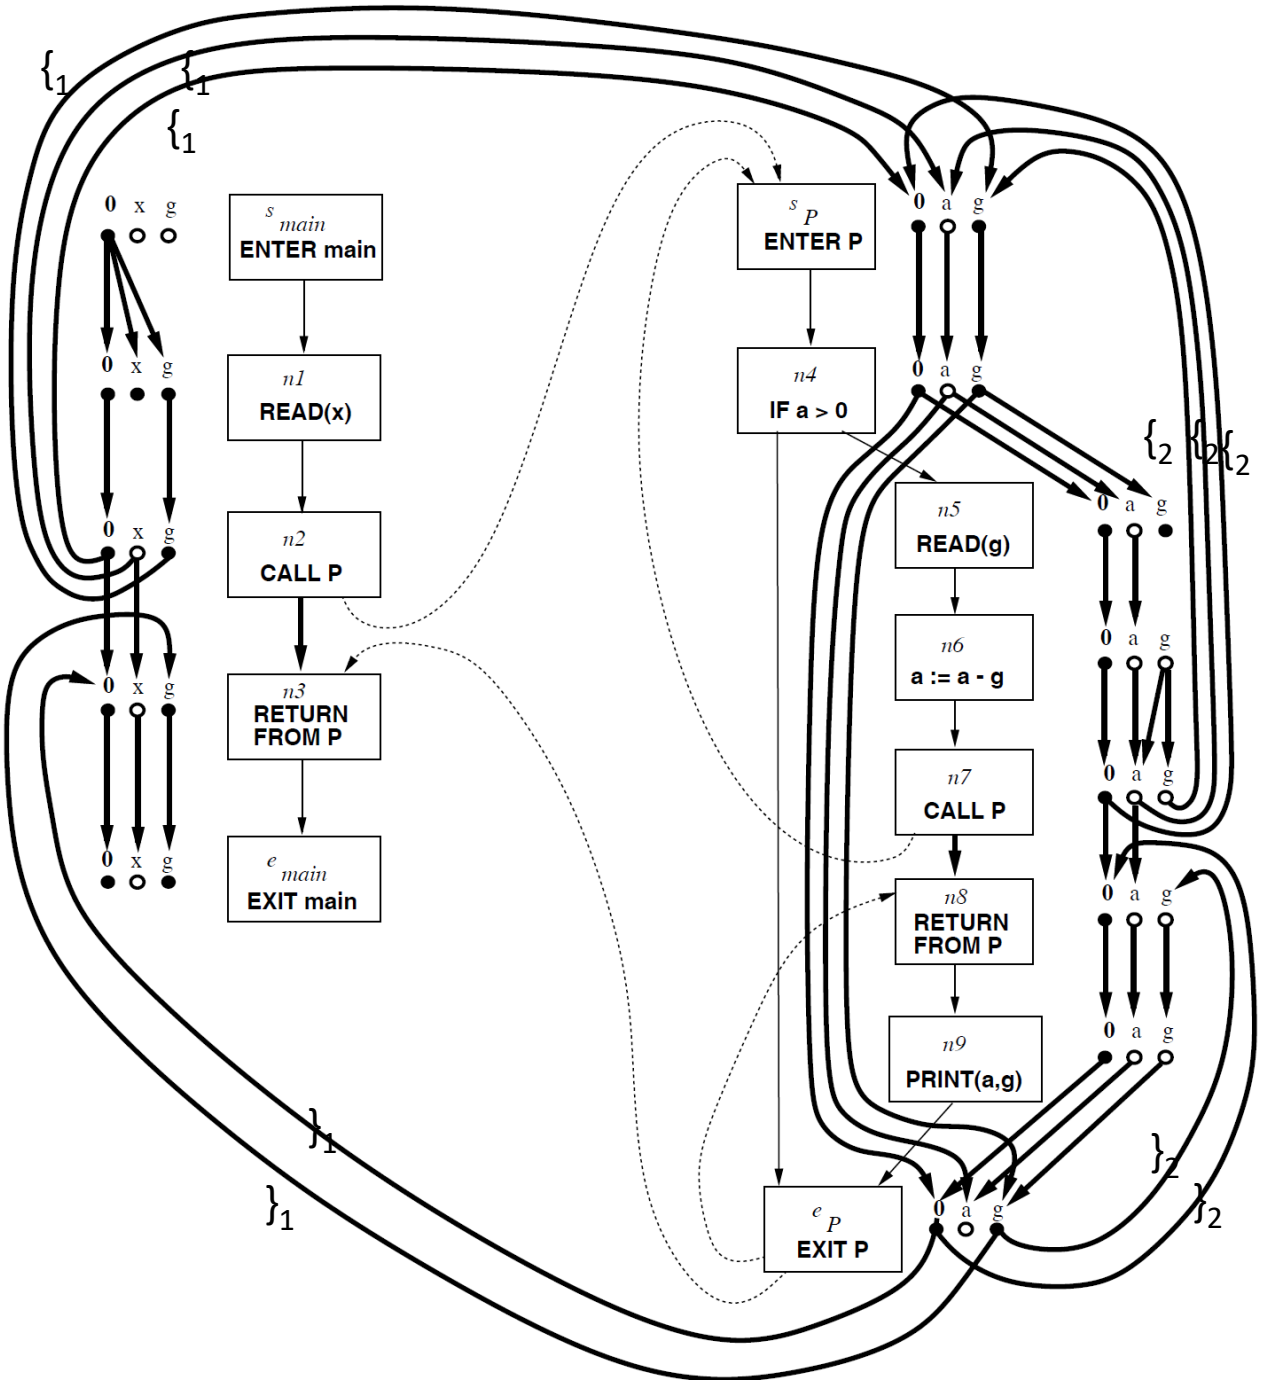
条件压缩函数vs图可达性

- 条件压缩函数在满足分配性时也可以表达为图可达性
- 例：空指针分析



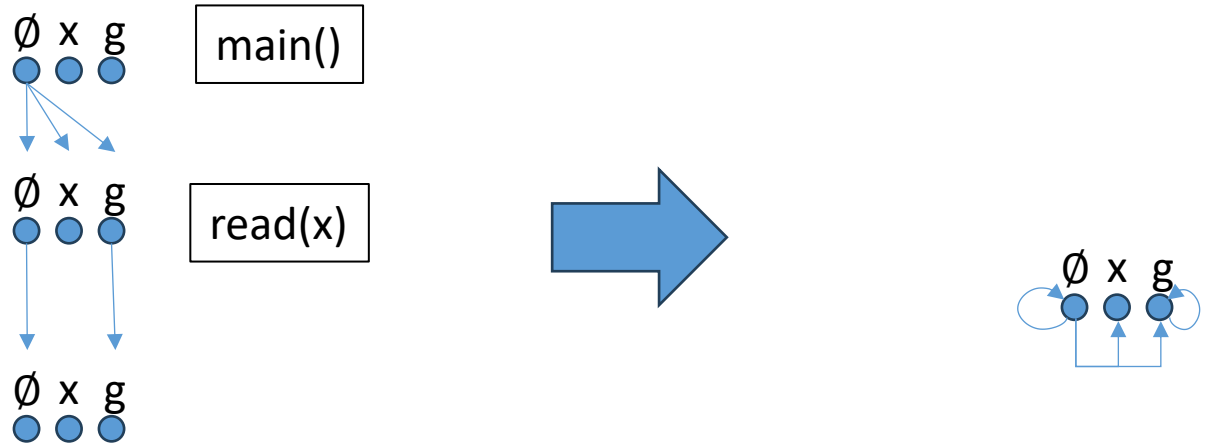
assert(p!=null)

例：未初始化变量分析


s main
ENTER main
n1
READ(x)
n2
CALL P
n3
RETURN FROM P
e main
EXIT main
s P
ENTER P
n4
IF a > 0
n5
READ(g)
n6
a := a - g
n7
CALL P
n8
RETURN FROM P
n9
PRINT(a,g)
e P
EXIT P
0 x g
0 a g

上下文敏感的流非敏感分析

- 将过程内的不同控制流节点对应的点合并即可，其余不变



上下文无关语言可达性问题



- 给定一个图，其中每条边上有标签
- 给定一个用上下文无关文法描述的语言L
- 对于图中任意结点v1、v2，确定是否存在从v1到v2的路径p，使得该路径上的标签组成了L中的句子。

计算方法

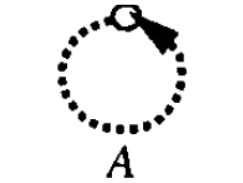


- 把原文法改写为右边只有最多两个符号的形式

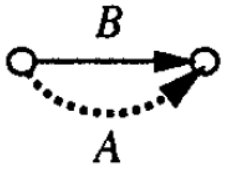
$$
\begin{aligned}
S \rightarrow\ & \{_1 E_1 && E_1 \rightarrow S\}_1 \\
\mid\ & \{_2 E_2 && E_2 \rightarrow S\}_2 \\
\mid\ & \ldots \\
\mid\ & SS \\
\mid\ & \epsilon
\end{aligned}
$$

计算方法

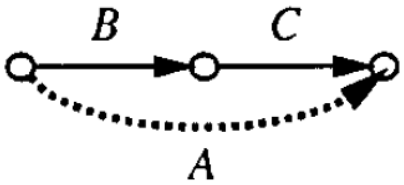
- 按如下三种模式不断添加边，直到没有边需要添加



(a) $A \rightarrow \varepsilon$



(b) $A \rightarrow B$

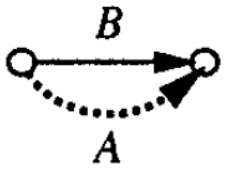


(c) $A \rightarrow B\ C$

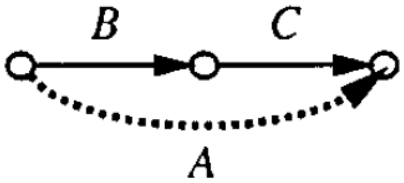
例子



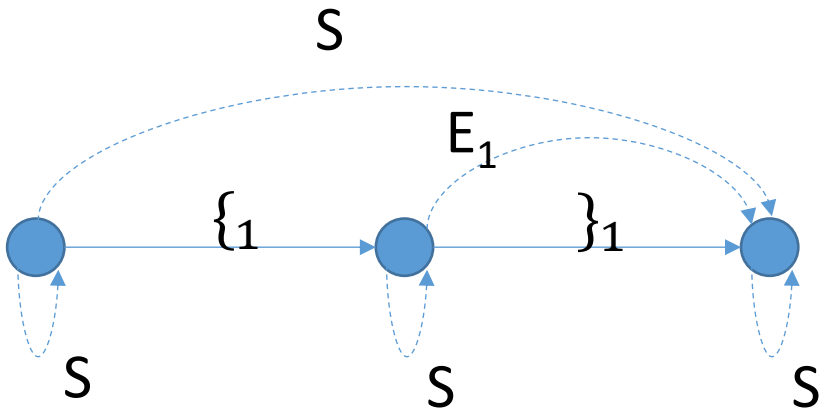
(a) $A \rightarrow \varepsilon$



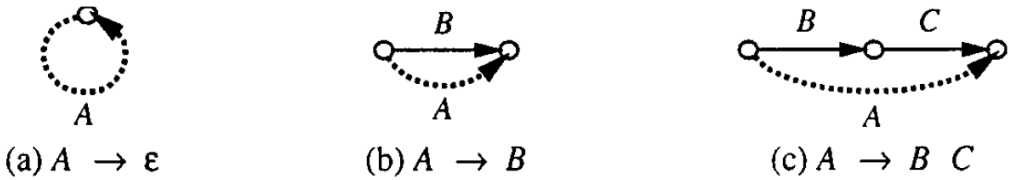
(b) $A \rightarrow B$



(c) $A \rightarrow B\ C$



伪码



For(each node) {
  根据规则(a)加边
}
ToVisit ←所有边
While(ToVisit.size > 0) {
  从ToVisit中取出任意边
  根据规则(b)加边
  查看前后结点的边的组合，根据规则(c)加边
  以上两步新加边加入ToVisit
}

安全性



- 给定任意控制流图上的调用/返回匹配的路径，该路径上算出的结果一定包含在CFL-Reachability算出的结果中。
  - 证明：
    - 根据之前的分析，对于单条路径，CFL-Reachability算出的可达性一定等价于传递函数算出的值
    - 由于该路径上调用/返回匹配，所以其结果一定仍然可达

精确性



- 给定任意n，以最近n次调用位置作为上下文的基于克隆的分析所产生的结果一定包括CFL-Reachability分析所产生的结果
  - 证明：
    - CFL-Reachability上的任意一条合法路径所产生的结果一定包含在克隆分析中
    - CFL-Reachability分析的结果就是所有合法路径的结果的合并

交集的情况



- 当数据流分析对应的合并操作为∩时，单位元素就变成了全集和全集中去掉一个元素对应的所有集合。用同样的方式可以组合得到所有集合。

术语：IFDS



- 前面介绍的可用CFL可达性解决的数据流分析问题又称为IFDS问题
  - Interprocedural, finite, distributive, subset problems
- 对应方法称为IFDS框架或者IFDS方法
  - 一般指采用下节课介绍的优化之后的算法

精确的上下文敏感分析意义有多大?



- 学术界有过多次试验，结论不完全一致
- 总体观点
  - 在面向对象程序中，上下文敏感分析比上下文非敏感分析精确很多
  - 精确的上下文敏感分析比不精确的上下文敏感分析通常更精确一些
  - 精确的上下文敏感分析所额外增加的开销是可接受的

作业1



- 设计一个过程间的可达定值分析
  - 给出半格定义和变换函数定义，特别是call语句和return语句的变换函数
  - 参数传递不认为是定值。比如，下面的程序中，标号2位置的c是由标号1的语句定值的而不是标号3的语句定值的

```
void main() {
  int a = 100; //1
  b(a) //3
}
void b(int c) {
  print(c);//2
}
```

  - 假设过程调用时不能传表达式，只能传变量，即
    - f(a+b)不合法，f(a)合法

作业1

- 根据前一页定义的可达定值分析，采用基于克隆的方法分析下面的程序，k至少应该设置成多少分析结果才能和精确的上下文敏感分析等价?
  - ```
    int g;
    void main(){
      int a = 10;
      g=a+1;
      h(a); h(a);
    }
    void h(int a) {
      x(a);  g++;  x(a);
    }
    void x(int a) {
      output(a);
    }
    ```
    ```

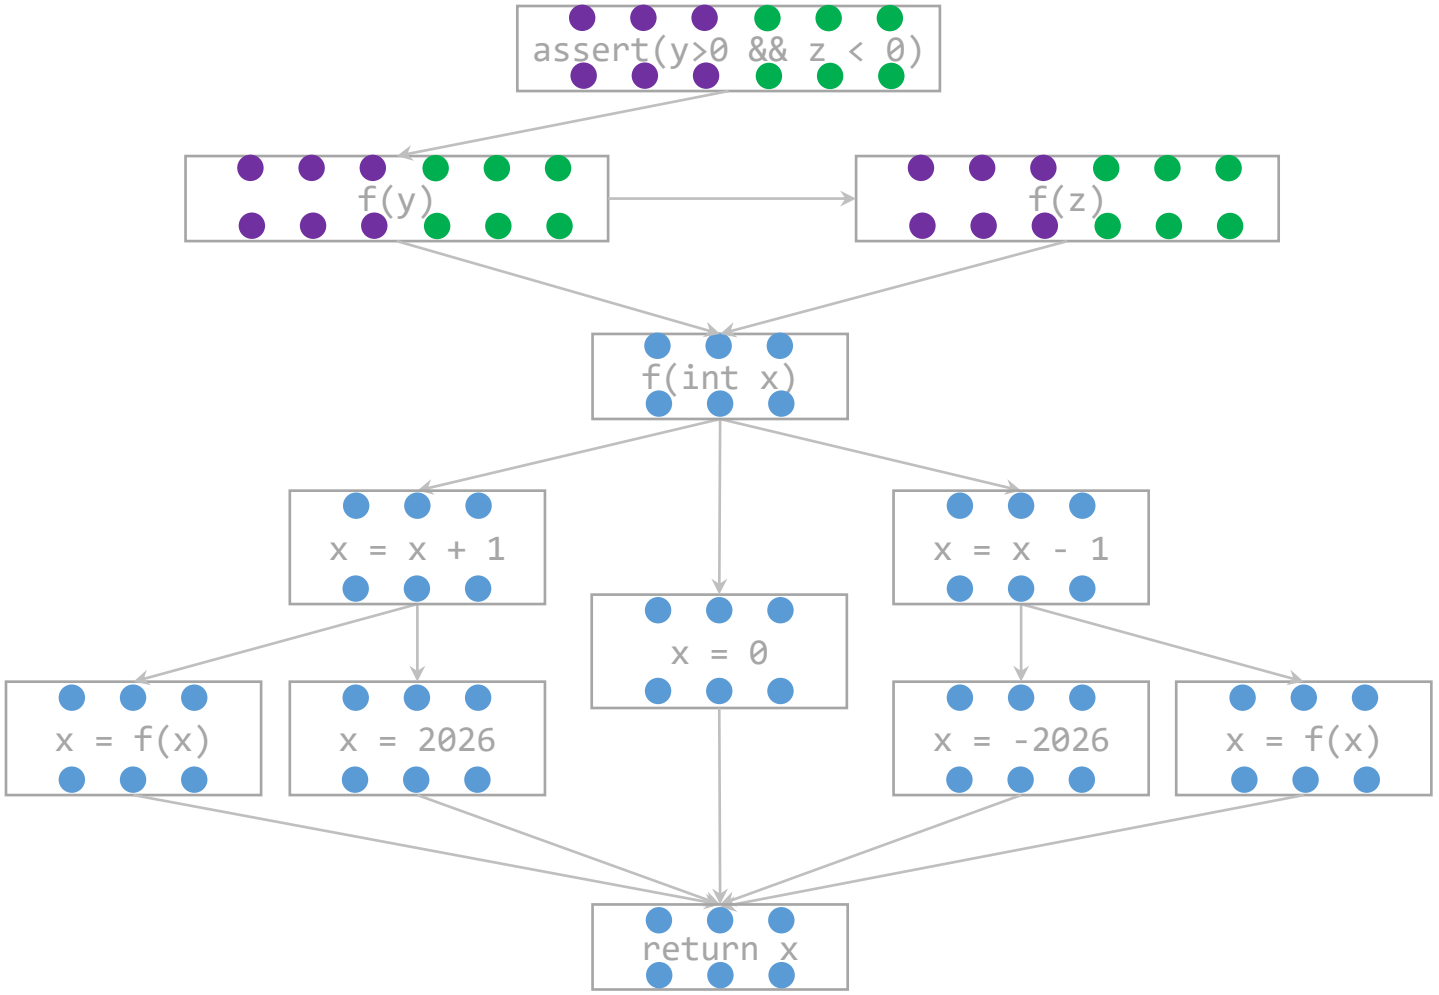
作业2

- 对右边这个程序做符号分析（抽象域参考下页图），考虑条件压缩函数，画出CFL-reachability的图。
  - 要求：根据输入值x的符号，在这个程序上能分析出返回值完全精确的符号结果
  - 注意一般性符号分析无法转CFL可达性，但本程序只涉及一元操作，所以可以用CFL可达性分析。
- 假设int是无界整数，分析是否存在一个足够大的k，使得基于克隆的方法在f的最后一行返回精确的结果。如果存在，请给出这样的k；如果不存在，请给出简要证明。请针对“调用位置作为上下文”和“函数名称作为上下文”两种情况分别分析。

```
int main() {
  ...
  assert(y > 0 && z < 0);
  f(y);f(z);
}
int f(int x){
  if(x < 0){
    x = x + 1;
    if(x == 0) x = 2026;
    else x = f(x);
  }
  else if(x > 0) {
    x = x - 1;
    if(x == 0) x = -2026;
    else x = f(x);
  }
  else x = 0;
  return x;
}
```

作业2：绘图基础

注：三个节点（从左到右依次）表示<0, =0, >0的情况；蓝、紫、绿分别表示x、y、z；浅灰色边仅表示控制流，不表示CFL-reachability图中的任何边；为了让图更加清晰，图中省略了部分节点和边。



参考资料



- Two Approaches to Interprocedural Data Flow Analysis
  - Micha Sharir and Amir Pnueli
  - New York Univerisity Technical Report, 1978
- Precise Interprocedural Dataflow Analysis via Graph Reachability
  - Thomas W. Reps, Susan Horwitz, Shmuel Sagiv
  - POPL 1995