

电子科技大学“研究生人文教育与学术交流月”讲座

程序设计语言知识增强的深度代码模型

汇报人：熊英飞

北京大学计算机学院软件研究所
长聘副教授、研究员

人工智能的两条主要途径


符号主义

- 从人类的知识体系出发构建智能



联结主义


- 从大自然进化的结果出发构造智能



辅助软件开发：当代AI最重要的应用之一



麦肯锡报告：采用生成式大模型辅助之后，软件研发成本可以节省 20%-45%。



程序天然符号系统，包含基于符号规则定义的

- 语法约束：()⁵(不合法)
- 类型约束：1+true不合法
- 语义约束：malloc分配的内存不调用free会导致泄漏

等，基于联结主义的神经网络难以学会这些规则，也难以基于规则推导。

How Secure is Code Generated by ChatGPT?

Raphaël Khoury¹, Anderson R. Avila², Jacob Brunelle¹, Baba Mamadou Camara¹

¹Université du Québec en Outaouais, Québec, Canada

²Institut national de la recherche scientifique, Québec, Canada

{raphael.khoury, anderson.raymundoavila, bruj30, camb12}@uqo.ca

Abstract—In recent years, large language models have been responsible for great advances in the field of artificial intelligence (AI). ChatGPT in particular, an AI chatbot developed and recently released by OpenAI, has taken the field to the next level. The conversational model is able not only to process human-like text, but also to translate natural language into code. However, the safety of programs generated by ChatGPT should not be overlooked. In this paper, we perform an experiment to address this issue. Specifically, we ask ChatGPT to generate a number of programs and evaluate the security of the resulting source code. We further investigate whether ChatGPT can be prodded to improve the security by appropriate prompts, and discuss the ethical aspects of using AI to generate code. Results suggest that ChatGPT is aware of potential vulnerabilities, but nonetheless often generates source code that are not robust to certain attacks.

Index Terms—Large language models, ChatGPT, code security, automatic code generation

I. INTRODUCTION

For years, large language models (LLM) have been demonstrating impressive performance on a number of natural language processing (NLP) tasks, such as sentiment analysis, natural language understanding (NLU), machine translation (MT) to name a few. This has been possible specially by means of increasing the model size, the training data and the model complexity [1]. In 2020, for instance, OpenAI announced GPT-3 [2], a new LLM with 175B parameters, 100 times larger than GPT-2 [3]. Two years later, ChatGPT [4], an artificial intelligence (AI) chatbot capable of understanding and generating human-like text, was released. The conversational AI model, empowered in its core by an LLM based on the Transformer architecture, has received great attention from both industry and academia, given its potential to be applied in different downstream tasks (e.g., medical reports [5], code generation [6], educational tool [7], etc).

Therefore, this paper is an attempt to answer the question of how secure is the source code generated by ChatGPT. Moreover, we investigate and propose follow-up questions that can guide ChatGPT to assess and regenerate more secure source code.

In this paper, we perform an experiment to evaluate the security of code generated by ChatGPT, fine-tuned from a model in the GPT-3.5 series. Specifically, we asked ChatGPT to generate 21 programs, in 5 different programming languages: C, C++, Python, html and Java. We then evaluated the generated program and questioned ChatGPT about any vulnerability present in the code. The results were worrisome. We found that, in several cases, the code generated by ChatGPT fell well below minimal security standards applicable in most contexts. In fact, when prodded to whether or not the produced code was secure, ChatGPT was able to recognize that it was not. The chatbot, however, was able to provide a more secure version of the code in many cases if explicitly asked to do so.

The remainder of this paper is organized as follows. Section II describes our methodology as well as provides an overview of the dataset. Section III details the security flaws we found in each program. In Section IV, we discuss our results, as well as the ethical consideration of using AI models to generate code. Section V surveys related works. Section VI discusses threats to the validity of our results. Concluding remarks are given in Section VII.

II. STUDY SETUP

A. Methodology

In this study, we asked ChatGPT to generate 21 programs, using a variety of programming languages. The programs generated serve a diversity of purpose, and each program was chosen to highlight risks of a specific vulnerability (eg.

GPT生成的代码片段中，至少76%包含各种安全漏洞。

符号知识也能帮助理解用户意图



程序的符号知识往往可以帮助正确理解当然任务的用户意图。

```
bool m(bool a, bool b) {  
    return _____  
}
```

加法语句很常见，多半
要用加法

不懂类型的
神经网络

参数都是bool形，与
或更有可能

懂类型的
神经网络

能否引导神经网络学习程序设计语言知识？

北京大学团队和毕业生相关工作

TreeGen [AAAI20]

- 使用Transformer实现玲珑框架
- 首个基于Transformer的代码生成工作
- 千万参数级别效果综合最优

Grape [IJCAI22]

- 引导神经网络学习文法规则

Tare [ICSE23]

- 引导神经网络学习Java类型规则

GrammarT5 [ICSE24]

- 拓展玲珑框架到预训练(200M)
- 亿级参数级别效果综合最优

DeepSeek-Coder [arxiv]

- 引导神经网络学习Def-Use关系
- 我国首个达到国际顶尖水平的开源代码模型

GrammarCoder [arxiv]


- 拓展玲珑框架到Decoder-only
- 十五亿级别效果综合最优

实现



玲珑框架L2S [TOSEM22]

- 通过语法规则序列表示程序
- 保证语法正确性
- 在生成过程中保持程序结构, 允许进一步分析



应用

ACS [ICSE17]

- 应用到修复, 首个高准确率(>70%)程序修复方法

Recoder [FSE21]

- 应用到修复, 首个达到SOTA的神经网络修复方法

ET [APRCOMP24]

- 应用到修复, 获国际修复大赛全球第一名

OCor [ASE20]

- 应用到代码搜索, 显著超过已有方法

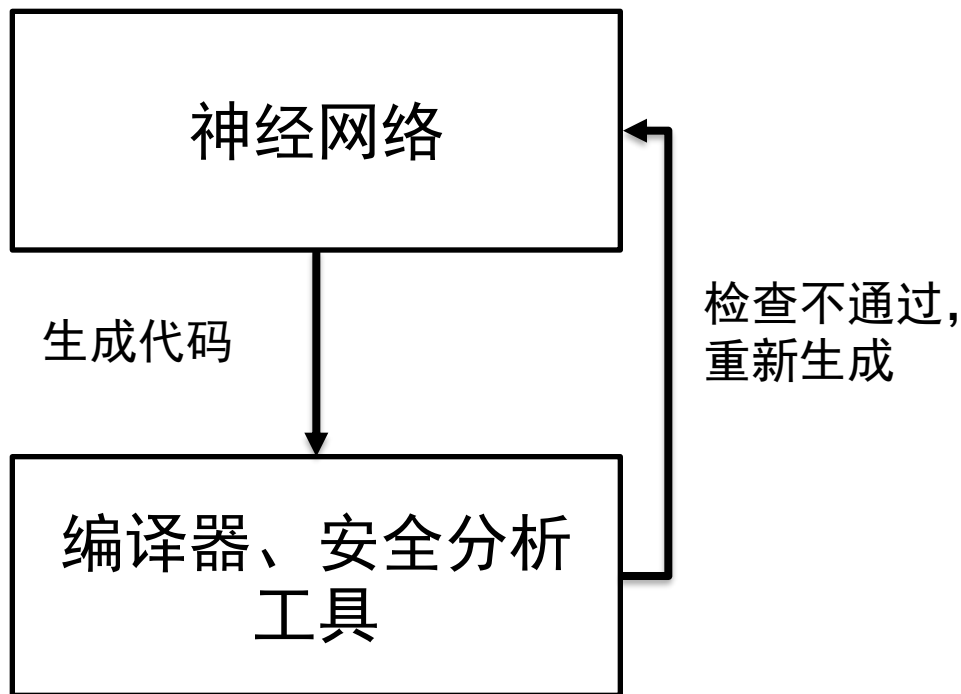
LEAM [ASE22]

- 应用到变异生成, 显著超过已有方法

能否让神经网络仅生成安全代码？



尝试1：生成之后检查



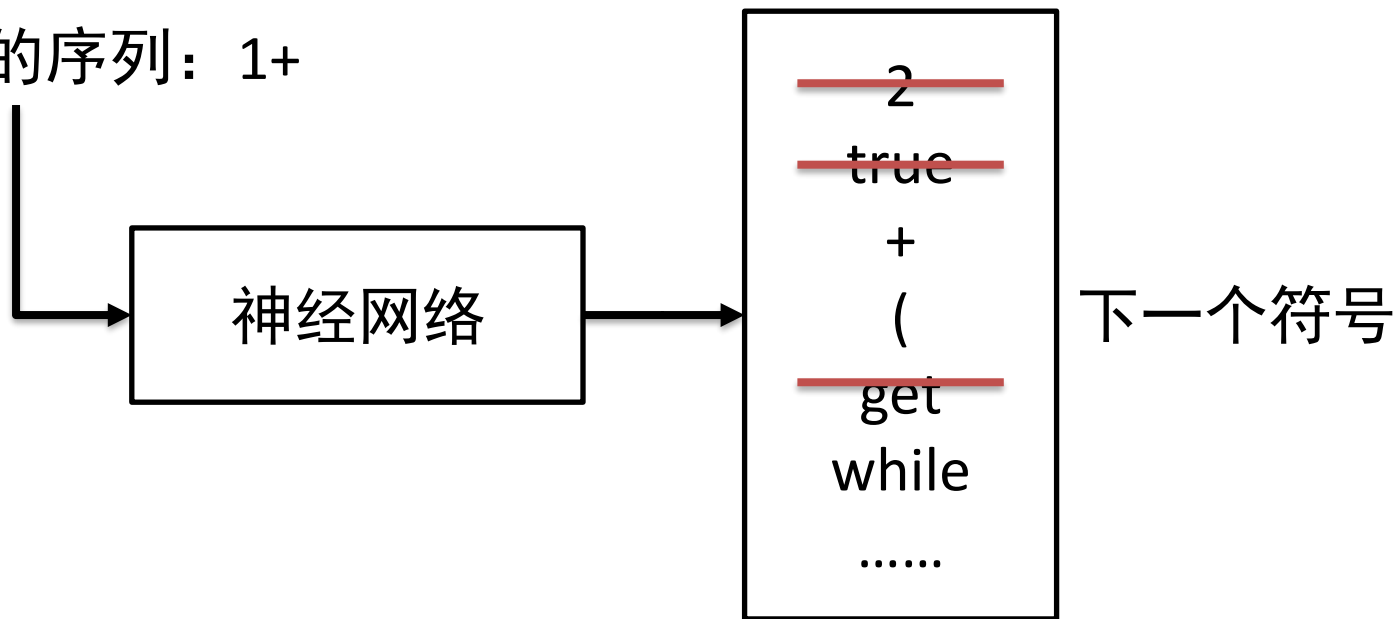
低效，反复生成包含同样错误的代码。

能否让神经网络仅生成安全代码？



尝试2-约束解码：在生成的时候实时分析，过滤掉不合法的输出

之前生成的序列：1+



部分程序的分析非常困难：神经网络输出的符号是BPE分词结果，甚至难以词法分析，更不要说语法解析代码结构。
分布错误：由于没有学会安全规则，神经网络可能学会错误的输出分布。

解决方案：语法规则序列表示程序

玲珑框架[TOSEM22]：通过语法规则序列表示程序。

程序

$x+y$

单词序列

$x, +, y$


规则序列

r_1, r_2, r_3

$r_1: E \rightarrow E + E$

$r_2: E \rightarrow x$

$r_3: E \rightarrow y$



优势1：约束解码变得容易

很容易就能保证语法正确

类型和语义正确性可以在部分AST上做分析

- `1 + "x" + Expr` //类型错误
- `if (BoolExpr) then x else x`
//如果输入`x=1`，期望输出2，则语义错误

做法：

- 采用抽象解释进行分析
- 首先在文法规则上进行预分析：知道非终结符对应的所有终结符
- 然后在部分程序上分析是否一定不正确

优势2：和语义更好的对应[ACL25-Finding]

相同语义

- `if (x<0) y=y+1;`
- `if (x < 0) {
 y = y + 1;
}`


在语法规则序列下相似
在单词序列下不同

不同语义

- `for i in range(1, 6):
 x = x + 1
 sum = sum + x`
- `for i in range(1, 6):
 x = x + 1
sum = sum + x`

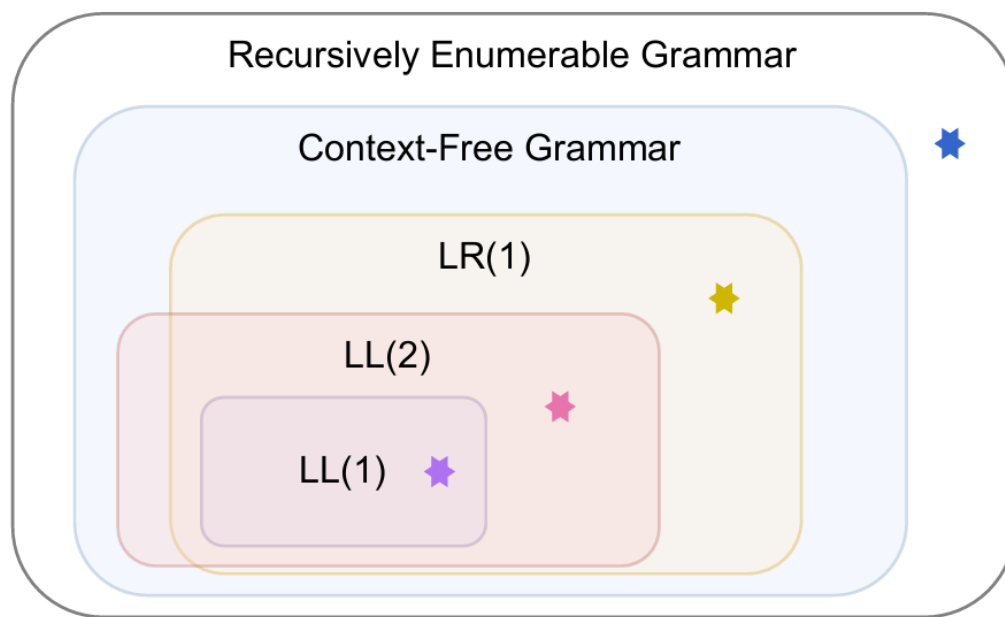
在语法规则序列下不同
在单词序列下相似

语义不同代码之间的编辑距离



优势3：更容易的代码解析[投稿中论文]

编程语言的解析越容易，模型表现就越好。



Language	Mean(%)
DSL _{LL(1)}	82.00
DSL _{LL(2)}	81.74
DSL _{LR(1)}	81.14
DSL _{NCFG}	80.41

优势3：更容易的代码解析[投稿中论文]

编程语言的解析越容易，模型表现就越好。

If n is an integer and $101 * n^2 \leq 3600$, what is the greatest possible value of n ?
 $n_0 = 101.0$ $n_1 = 2.0$
 $n_2 = 3600.0$

a. Question

```
1. import math
2. n0 = 101.0
3. n1 = 2.0
4. n2 = 3600.0
5. t0 = n2 / n0
6. t1 = math.sqrt(max(0, t0))
7. answer = math.floor(t1)
```

b. Answer in DSL_{LR(1)}

```
1. import math
2. n0 = 101.0
3. n1 = 2.0
4. n2 = 3600.0
5. t0 = / n2 n0
6. t1 = <call> <attr> math.sqrt(<call> max(0, t0))
7. answer = <call> <attr> math.floor(t1)
```

c. Answer in DSL_{LL(1)}

```
1. import math
2. <exp> n0 = 101.0
3. <exp> n1 = 2.0
4. <exp> n2 = 3600.0
5. <exp> t0 = <exp> / n2 n0
6. <exp> t1 = <exp> <call> <exp> <attr> math.sqrt(<exp> <call> max(0, t0))
7. <exp> answer = <exp> <call> <exp> <attr> math.floor(t1)
```

d. Answer in DSL_{LL(2)}

```
1. import math
2. n0 = 101.0 ; n0
3. n1 = 2.0 ; n1
4. n2 = 3600.0 ; n2
5. t0 = n2 / n0 ; t0
6. t1 = math.sqrt(max(0, t0)) ; t1
7. answer = math.floor(t1) ; ans
```

e. Answer in DSL_{CSG}

Language	Mean(%)
DSL _{LL(1)}	82.00
DSL _{LL(2)}	81.74
DSL _{LR(1)}	81.14
DSL _{NCFG}	80.41

优势3：更容易的代码解析[投稿中论文]

- 语法序列表示属于LL(1)
- 比大多数主流编程语言都要容易解析
 - Python: 非上下文无关语言
 - Java: LR

北京大学团队和毕业生相关工作

实现



玲珑框架L2S [TOSEM22]

- 通过语法规则序列表示程序
- 保证语法正确性
- 在生成过程中保持程序结构，允许进一步分析



应用

TreeGen [AAAI20]

- 使用Transformer实现玲珑框架
- 首个基于Transformer的代码生成工作
- 千万参数级别效果综合最优

Grape [IJCAI22]

- 引导神经网络学习文法规则

Tare [ICSE23]

- 引导神经网络学习Java类型规则

GrammarT5 [ICSE24]

- 拓展玲珑框架到预训练(200M)
- 亿级参数级别效果综合最优

DeepSeek-Coder [arxiv]

- 引导神经网络学习Def-Use关系
- 我国首个达到国际顶尖水平的开源代码模型

GrammarCoder [arxiv]

- 拓展玲珑框架到Decoder-only
- 十五亿级别效果综合最优

ACS [ICSE17]

- 应用到修复，首个高准确率(>70%)程序修复方法

Recoder [FSE21]

- 应用到修复，首个达到SOTA的神经网络修复方法

ET [APRCOMP24]

- 应用到修复，获国际修复大赛全球第一名

OCor [ASE20]

- 应用到代码搜索，显著超过已有方法

LEAM [ASE22]

- 应用到变异生成，显著超过已有方法

采用神经网络实现玲珑框架[AAAI 20]

用Transformer实现玲珑框架

- 最早的采用Transformer生成代码的工作
- 将Transformer适配到语法规则上形成TreeGen

	Model	StrAcc	Acc+	BLEU
Plain	LPN (Ling et al. 2016)	6.1	–	67.1
	SEQ2TREE (Dong and Lapata 2016)	1.5	–	53.4
	YN17 (Yin and Neubig 2017)	16.2	~18.2	75.8
	ASN (Rabinovich, Stern, and Klein 2017)	18.2	–	77.6
	ReCode (Hayati et al. 2018)	19.6	–	78.4
	TreeGen-A	25.8	25.8	79.3
Structural	ASN+SUPATT (Rabinovich, Stern, and Klein 2017)	22.7	–	79.2
	SZM19 (Sun et al. 2019)	27.3	30.3	79.6
	TreeGen-B	31.8	33.3	80.8

北京大学团队和毕业生相关工作

TreeGen [AAAI20]

- 使用Transformer实现玲珑框架
- 首个基于Transformer的代码生成工作
- 千万参数级别效果综合最优

Grape [IJCAI22]

- 引导神经网络学习文法规则

Tare [ICSE23]

- 引导神经网络学习Java类型规则

GrammarT5 [ICSE24]

- 拓展玲珑框架到预训练(200M)
- 亿级参数级别效果综合最优

DeepSeek-Coder [arxiv]

- 引导神经网络学习Def-Use关系
- 我国首个达到国际顶尖水平的开源代码模型

GrammarCoder [arxiv]

- 拓展玲珑框架到Decoder-only
- 十五亿级别效果综合最优

实现



玲珑框架L2S [TOSEM22]

- 通过语法规则序列表示程序
- 保证语法正确性
- 在生成过程中保持程序结构, 允许进一步分析



应用

ACS [ICSE17]

- 应用到修复, 首个高准确率(>70%)程序修复方法

Recoder [FSE21]

- 应用到修复, 首个达到SOTA的神经网络修复方法

ET [APRCOMP24]

- 应用到修复, 获国际修复大赛全球第一名

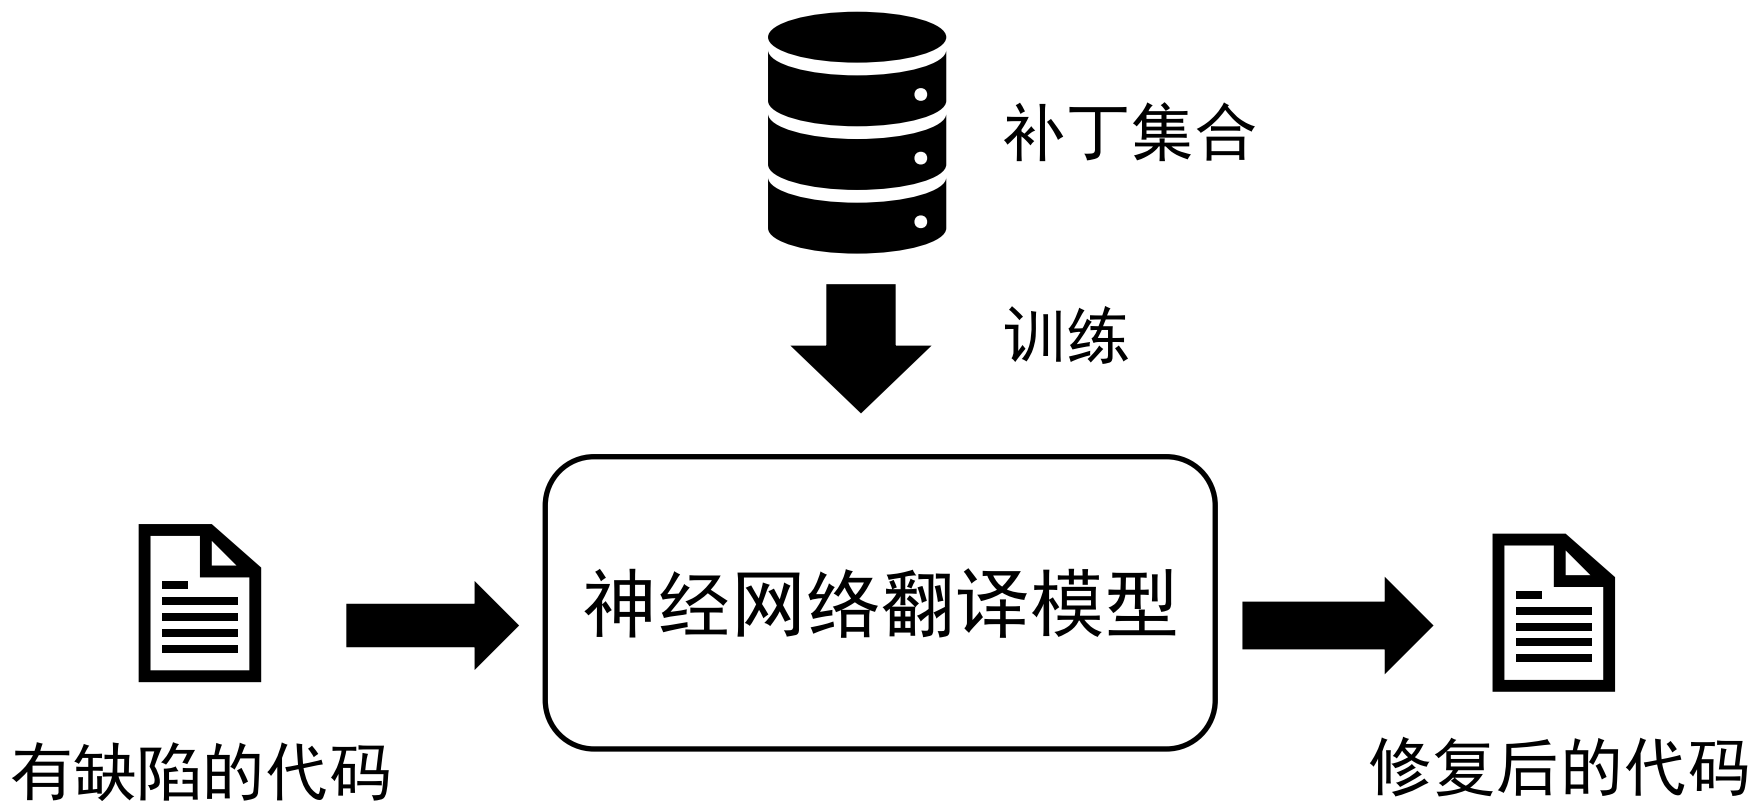
OCor [ASE20]

- 应用到代码搜索, 显著超过已有方法

LEAM [ASE22]

- 应用到变异生成, 显著超过已有方法

将补丁看做是修复前后的代码对



双向变换研究中的发现 [MODELS'11 MIP]

基于前后状态的表示是低效的

```
cfa.createEdge(fromNode, Branch.UNCOND, finallyNode);
```

```
cfa.createEdge(fromNode, Branch.ON_EX, finallyNode);
```

1. 需要学会如何发现修改
2. 修改表示很长 (13 tokens)

基于差别的表示更高效

```
modify(9, ON_EX)
```

1. 直接给出修改
2. 表示更短 (3 tokens)

设计了关于修改的语法

1. *Edits* → *Edit; Edits* | *end*
2. *Edit* → *Insert* | *Modify*
3. *Insert* → *insert*(*<HLStatement>*)
4. *Modify* → *modify*(
 <ID of an AST Node with a NTS>,
 <the same NTS as the above NTS>)
5. *<Any NTS in HL>* →
 copy(*<ID of an AST Node with the same NTS>*)
 | *<The original production rules in HL>*
6. *<HLIdentifier>* → *placeholder*
 | *<Identifiers in the training set>*

保证修改之后的代码是语法正确的

在玲珑框架下，采用TreeGen来构造概率模型，并用修改操作定义了程序空间

Table 2: Comparison without Perfect Fault Localization

Project	jGenProg	HDRepair	Nopol	CapGen	SketchFix	FixMiner	SimFix	TBar	DLFix	PraPR	AVATAR	Recoder
Chart	0/7	0/2	1/6	4/4	6/8	5/8	4/8	9/14	5/12	4/14	5/12	8/14
Closure	0/0	0/7	0/0	0/0	3/5	5/5	6/8	8/12	6/10	12/62	8/12	17/31
Lang	0/0	2/6	3/7	5/5	3/4	2/3	9/13	5/14	5/12	3/19	5/11	9/15
Math	5/18	4/7	1/21	12/16	7/8	12/14	14/26	18/36	12/28	6/40	6/13	15/30
Time	0/2	0/1	0/1	0/0	0/1	1/1	1/1	1/3	1/2	0/7	1/3	2/2
Mockito	0/0	0/0	0/0	0/0	0/0	0/0	0/0	1/2	1/1	1/6	2/2	2/2
Total	5/27	6/23	5/35	21/25	19/26	25/31	34/56	42/81	30/65	26/148	27/53	53/94
P(%)	18.5	26.1	14.3	84.0	73.1	80.6	60.7	51.9	46.2	17.6	50.9	56.4

In the cells, x/y:x denotes the number of correct patches, and y denotes the number of patches that can pass all the test cases.

神经网络修复四年多来首次超过传统修复的效果
录用于ESEC/FSE21，是该会议上引用最多的论文

北京大学团队和毕业生相关工作

TreeGen [AAAI20]

- 使用Transformer实现玲珑框架
- 首个基于Transformer的代码生成工作
- 千万参数级别效果综合最优

Grape [IJCAI22]

- 引导神经网络学习文法规则

Tare [ICSE23]

- 引导神经网络学习Java类型规则

GrammarT5 [ICSE24]

- 拓展玲珑框架到预训练(200M)
- 亿级参数级别效果综合最优

DeepSeek-Coder [arxiv]

- 引导神经网络学习Def-Use关系
- 我国首个达到国际顶尖水平的开源代码模型

GrammarCoder [arxiv]


- 拓展玲珑框架到Decoder-only
- 十五亿级别效果综合最优

实现



玲珑框架L2S [TOSEM22]

- 通过语法规则序列表示程序
- 保证语法正确性
- 在生成过程中保持程序结构, 允许进一步分析



应用

ACS [ICSE17]

- 应用到修复, 首个高准确率(>70%)程序修复方法

Recoder [FSE21]

- 应用到修复, 首个达到SOTA的神经网络修复方法

ET [APRCOMP24]

- 应用到修复, 获国际修复大赛全球第一名

OCor [ASE20]

- 应用到代码搜索, 显著超过已有方法

LEAM [ASE22]

- 应用到变异生成, 显著超过已有方法

团队毕业生陈俊洁和张令明的工作
将Recoder的输入输出交换之后训练
缺陷修复工具→缺陷植入工具

Table 4: Overall effectiveness in mutation-based FL

FL	Tech.	Top-1	Top-3	Top-5	MFR	MAR
Metallaxis	Major	35	92	114	9.56	12.42
	PIT	56	102	128	8.16	11.83
	DM	19	47	98	16.64	20.65
	LEAM	118	182	188	3.86	4.57
MUSE	Major	35	89	111	10.99	13.11
	PIT	52	97	124	9.15	11.72
	DM	18	53	94	18.70	22.47
	LEAM	126	181	189	3.88	5.05

北京大学团队和毕业生相关工作

TreeGen [AAAI20]

- 使用Transformer实现玲珑框架
- 首个基于Transformer的代码生成工作
- 千万参数级别效果综合最优

Grape [IJCAI22]

- 引导神经网络学习文法规则

Tare [ICSE23]

- 引导神经网络学习Java类型规则

GrammarT5 [ICSE24]

- 拓展玲珑框架到预训练(200M)
- 亿级参数级别效果综合最优

DeepSeek-Coder [arxiv]

- 引导神经网络学习Def-Use关系
- 我国首个达到国际顶尖水平的开源代码模型

GrammarCoder [arxiv]


- 拓展玲珑框架到Decoder-only
- 十五亿级别效果综合最优

实现



玲珑框架L2S [TOSEM22]

- 通过语法规则序列表示程序
- 保证语法正确性
- 在生成过程中保持程序结构, 允许进一步分析



应用

ACS [ICSE17]

- 应用到修复, 首个高准确率(>70%)程序修复方法

Recoder [FSE21]

- 应用到修复, 首个达到SOTA的神经网络修复方法

ET [APRCOMP24]

- 应用到修复, 获国际修复大赛全球第一名

OCor [ASE20]

- 应用到代码搜索, 显著超过已有方法

LEAM [ASE22]

- 应用到变异生成, 显著超过已有方法

玲珑框架局限性

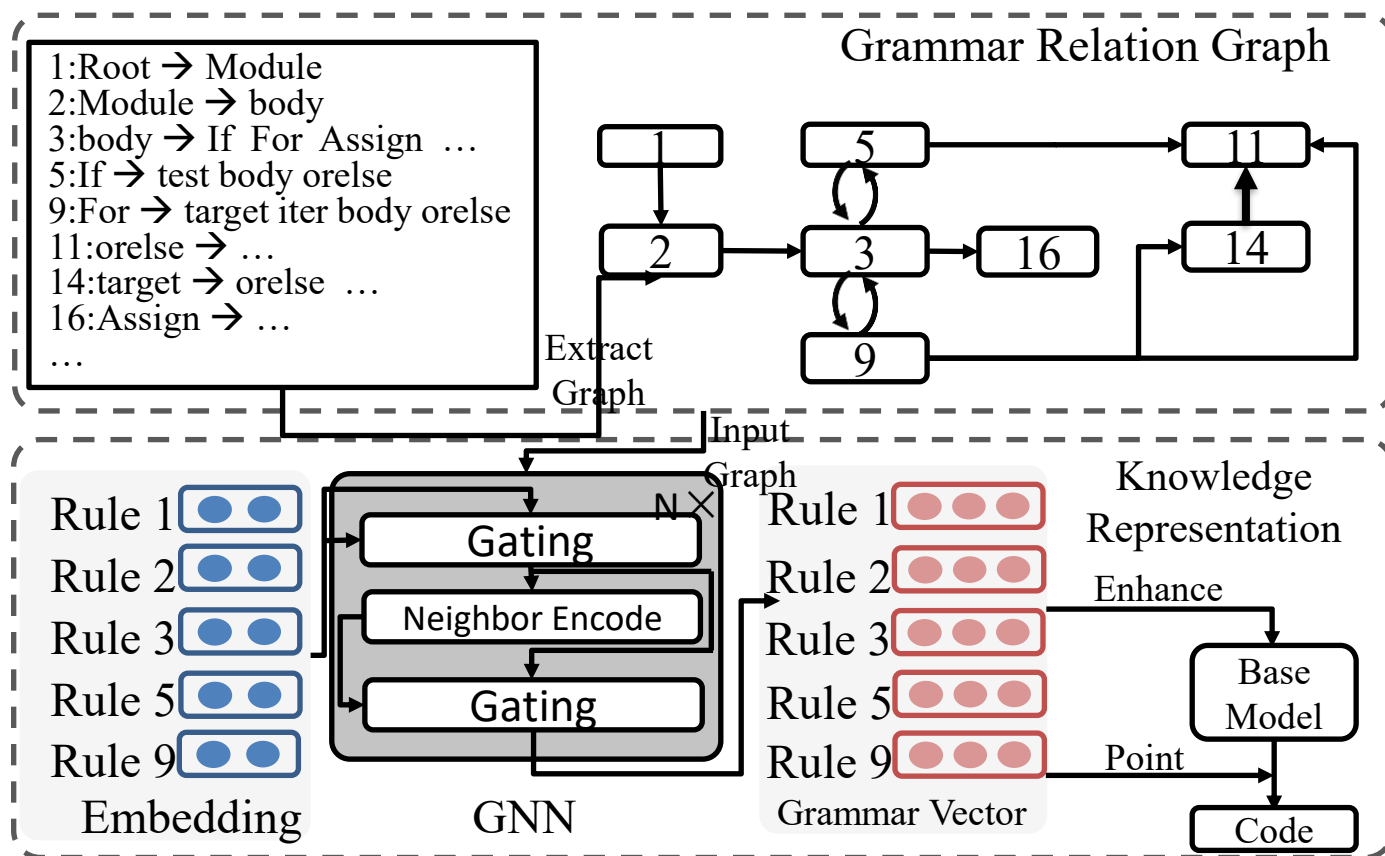
在玲珑框架主要从外部加上语法、类型等约束
神经网络并没有全面了解语言中文法规则和类型规则的定义

语法规则在神经网络中编码为数字

ifstmt -> 'if' '(' boolExpr ')' stmt	10
whilestat -> 'while' '(' boolExpr ')' stmt	11
boolExpr -> andExpr	12
boolExpr -> orExpr	13

神经网络并不了解这些数字的含义，有可能预测出10, 11这样的序列，但应用10之后是无法应用11的

基于语法规则的前后关联关系构造语法关系图，基于该图构建图神经网络，然后通过该图的训练学出规则的向量表示，类似 Word2Vec。



提升TreeGen在不同应用上效果0.8-6.4个百分点。
超越参数量和训练集都更大的预训练模型。


Method	Code Generation					Semantic Parsing		Regex Synthesis
	HearthStone			Django	Concode	Atis	Job	StrReg
	StrAcc	BLEU	Acc+	StrAcc	StrAcc	ExeAcc	ExeAcc	DFAAcc
KCAZ13 [Kwiatkowski <i>et al.</i> , 2013]	-	-	-	-	-	89.0	-	-
WKZ14 [Wang <i>et al.</i> , 2014]	-	-	-	-	-	91.3	90.7	-
Neural Networks	SEQ2TREE [Dong and Lapata, 2016]	-	-	-	-	84.6	90.0	-
	ASN+SUPATT [Rabinovich <i>et al.</i> , 2017]	22.7	79.2	-	-	85.9	92.9	-
	TRANX [Yin and Neubig, 2018]	-	-	-	73.7	86.3	90.0	-
	Iyer-Simp+200 idioms [Iyer <i>et al.</i> , 2018]	-	-	-	12.20	-	-	-
	GNN-Edge [Shaw <i>et al.</i> , 2019]	-	-	-	-	87.1	-	-
	SoftReGex [Park <i>et al.</i> , 2019]	-	-	-	-	-	-	28.2
	TreeGen [Sun <i>et al.</i> , 2020]	30.3±1.061	80.8	33.3	76.4	16.6	89.6±0.329	91.5±0.586
								22.5
GPT-2 [Radford <i>et al.</i> , 2019]	16.7	71	18.2	62.3	17.3	84.4	92.1	24.6
CodeGPT [Lu <i>et al.</i> , 2021]	27.3	75.4	30.3	68.9	18.3	87.5	92.1	22.49
TreeGen + Grape	33.6±1.255	85.4	36.3	77.3	17.6	92.16±0.167	92.55±0.817	28.9

参数量：TreeGen+Grape: 3510万 GPT-2、CodeGPT: 1.1亿

千万参数级别最好模型

北京大学团队和毕业生相关工作

实现



应用

TreeGen [AAAI20]

- 使用Transformer实现玲珑框架
- 首个基于Transformer的代码生成工作
- 千万参数级别效果综合最优

Grape [IJCAI22]

- 引导神经网络学习文法规则

Tare [ICSE23]

- 引导神经网络学习Java类型规则

GrammarT5 [ICSE24]

- 拓展玲珑框架到预训练(200M)
- 亿级参数级别效果综合最优

DeepSeek-Coder [arxiv]

- 引导神经网络学习Def-Use关系
- 我国首个达到国际顶尖水平的开源代码模型

GrammarCoder [arxiv]

- 拓展玲珑框架到Decoder-only
- 十五亿级别效果综合最优

玲珑框架L2S [TOSEM22]

- 通过语法规则序列表示程序
- 保证语法正确性
- 在生成过程中保持程序结构, 允许进一步分析

ACS [ICSE17]

- 应用到修复, 首个高准确率(>70%)程序修复方法

Recoder [FSE21]

- 应用到修复, 首个达到SOTA的神经网络修复方法

ET [APRCOMP24]

- 应用到修复, 获国际修复大赛全球第一名

OCor [ASE20]

- 应用到代码搜索, 显著超过已有方法

LEAM [ASE22]

- 应用到变异生成, 显著超过已有方法

完整类型系统由多条规则组成，很复杂，难以从数据中直接学会

<i>Term typing</i>			
$\frac{x:C \in \Gamma}{\Gamma \vdash x : C}$	$\Gamma \vdash t : C$	(T-VAR)	
$\frac{\Gamma \vdash t_0 : C_0 \quad \text{fields}(C_0) = \bar{C} \bar{F}}{\Gamma \vdash t_0.f_i : C_i}$		(T-FIELD)	
$\frac{\Gamma \vdash t_0 : C_0 \quad \text{mtype}(m, C_0) = \bar{D} \rightarrow C \quad \Gamma \vdash \bar{c} : \bar{C} \quad \bar{C} <: \bar{D}}{\Gamma \vdash t_0.m(\bar{c}) : C}$		(T-INVK)	
$\frac{\text{fields}(C) = \bar{D} \bar{F} \quad \Gamma \vdash \bar{c} : \bar{C} \quad \bar{C} <: \bar{D}}{\Gamma \vdash \text{new } C(\bar{c}) : C}$		(T-NEW)	
$\frac{\Gamma \vdash t_0 : D \quad D <: C}{\Gamma \vdash (C)t_0 : C}$		(T-UCAST)	
			$\frac{\Gamma \vdash t_0 : D \quad C <: D \quad C \neq D}{\Gamma \vdash (C)t_0 : C} \quad \text{(T-DCAST)}$
			$\frac{\Gamma \vdash t_0 : D \quad C \not<: D \quad D \not<: C \quad \text{stupid warning}}{\Gamma \vdash (C)t_0 : C} \quad \text{(T-SCAST)}$
<i>Method typing</i>			$\text{M OK in } C$
$\frac{\bar{x} : \bar{C}, \text{this} : C \vdash t_0 : E_0 \quad E_0 <: C_0 \quad \text{CT}(C) = \text{class } C \text{ extends } D \{ \dots \} \quad \text{override}(m, D, \bar{C} \rightarrow C_0)}{C_0.m(\bar{C} \bar{x}) \{ \text{return } t_0; \} \text{ OK in } C}$			
<i>Class typing</i>			$C \text{ OK}$
$\frac{K = C(\bar{D} \bar{g}, \bar{C} \bar{F}) \quad \{ \text{super}(\bar{g}); \text{this}.\bar{f} = \bar{F}; \} \quad \text{fields}(D) = \bar{D} \bar{g} \quad \bar{M} \text{ OK in } C}{\text{class } C \text{ extends } D \{ \bar{C} \bar{F}; K \bar{M} \} \text{ OK}}$			

Figure 19-4: Featherweight Java (typing)

修复工具生成的程序中只有30%-40%是类型正确的

假设单条规则是容易学会的

1. 设计数据结构表征学习单条规则所需的信息
2. 修改文法规则记录类型推导的结果




类型规则

$$\frac{\Gamma \vdash v : D \quad \Gamma \vdash t : C \quad C <: D}{\Gamma \vdash v = t : \text{Void}}$$



类型关系



T-Graph



T-Grammar

- (1) AST和类型
- (2) 变量和类型
- (3) 类型之间的子关系

应用于缺陷修复，形成Tare方法（参数量3510万），成功修复的数量提升26.5%

Project	Bugs	CapGen	SimFix	TBar	DLFix	Hanabi	Recoder	Recoder-F	Recoder-T	Tare
Chart	26	4/4	4/8	9/14	5/12	3/5	8/14	9/15	8/16	11/16
Closure	133	0/0	6/8	8/12	6/10	-/-	13/33	14/36	15/31	15/29
Lang	64	5/5	9/13	5/14	5/12	4/4	9/15	9/15	11/23	13/22
Math	106	12/16	14/26	18/36	12/28	19/22	15/30	16/31	16/40	19/42
Time	26	0/0	1/1	1/3	1/2	2/2	2/2	2/2	2/4	2/4
Mockito	38	0/0	0/0	1/2	1/1	-/-	2/2	2/2	2/2	2/2
Total	393	21/25	34/56	42/81	30/65	28/33	49/96	52/101	54/116	62/115

在2024年的国际修复比赛上获得Java组冠军
超过其他团队用几亿、几十亿参数预训练模型构建的工具

北京大学团队和毕业生相关工作

TreeGen [AAAI20]

- 使用Transformer实现玲珑框架
- 首个基于Transformer的代码生成工作
- 千万参数级别效果综合最优

Grape [IJCAI22]

- 引导神经网络学习文法规则

Tare [ICSE23]

- 引导神经网络学习Java类型规则

GrammarT5 [ICSE24]

- 拓展玲珑框架到预训练(200M)
- 亿级参数级别效果综合最优

DeepSeek-Coder [arxiv]

- 引导神经网络学习Def-Use关系
- 我国首个达到国际顶尖水平的开源代码模型

GrammarCoder [arxiv]


- 拓展玲珑框架到Decoder-only
- 十五亿级别效果综合最优

实现



玲珑框架L2S [TOSEM22]

- 通过语法规则序列表示程序
- 保证语法正确性
- 在生成过程中保持程序结构, 允许进一步分析



应用

ACS [ICSE17]

- 应用到修复, 首个高准确率(>70%)程序修复方法

Recoder [FSE21]

- 应用到修复, 首个达到SOTA的神经网络修复方法

ET [APRCOMP24]

- 应用到修复, 获国际修复大赛全球第一名

OCor [ASE20]

- 应用到代码搜索, 显著超过已有方法

LEAM [ASE22]

- 应用到变异生成, 显著超过已有方法

现代大型代码预训练模型都采用多种编程语言训练。
不同编程语言语法规则、类型规则各不相同。
以上方法能否应用于预训练模型？

```
<identifier> ::= <initial> | <initial> <more>  
<initial> ::= <letter> | _ | $  
<more> ::= <final> | <more> <final>  
<final> ::= <initial> | <digit>  
<letter> ::= a | b | c | ... z | A | B | ... | Z  
<digit> ::= 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9
```

Java文法

Python文法

```
stringliteral    ::= [stringprefix](shortstring | longstring)  
stringprefix    ::= "r" | "u" | "R" | "U" | "f" | "F"  
                | "fr" | "Fr" | "fR" | "FR" | "rf" | "rF" | "Rf" | "RF"  
shortstring     ::= ''' shortstringitem* ''' | ''' shortstringitem* '''  
longstring      ::= ''' longstringitem* ''' | ''' longstringitem* '''  
shortstringitem ::= shortstringchar | stringescapeseq  
longstringitem  ::= longstringchar | stringescapeseq  
shortstringchar ::= <any source character except "\" or newline or the quote>  
longstringchar  ::= <any source character except "\">  
stringescapeseq ::= "\" <any source character>
```

可简单将文法合并为更大的文法
神经网络能学会不同文法规则之间的关联
其他预训练技术（如BPE分词）也能做到和文法兼容

```
Root -> JavaRoot
      | PythonRoot
      | ...
JavaRoot -> Imports Classes
...
```

学习“声明-使用”关系

已有预训练任务随机排列文件
神经网络可能先看到方法调用再看到方法定义

上下文依赖解析：

- 从文件中挖掘“声明-使用”关系
- 对文件排序，保证声明出现在使用之前

GrammarT5 [ICSE24]

- 应用语法规则编码
- 5亿参数以下的综合效果最优代码生成模型

GrammarCoder [arxiv25]

- 和快手合作训练
- 应用语法规则编码
- 15亿参数级别效果综合最优

DeepSeekCoder [arxiv24]

- 和深度求索公司合作训练
- 引导学习“声明-使用”关系
- 我国首个达到国际顶尖水平的开源代码模型

- 代码是符号主义的产物
- 联结主义的神经网络天然不擅长学习和推断符号规则
- 结合符号方法和神经网络可有效提升代码任务的效果
 - 只高效搜索符号约束下的目标程序空间
 - 引导神经网络学习符号知识